



การพยากรณ์ทิศทางราคาหุ้นด้วย LSTM และ Attention Mechanism
ร่วมกับ Explainable AI: การเปรียบเทียบ SHAP กับ Pearson
Correlation

โดย

นายธำรง แซ่เจิน
นายวชิรวิทย์ แก้วแดง

โครงการพิเศษนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
วิทยาศาสตรบัณฑิต
สาขาวิชาวิทยาการคอมพิวเตอร์
คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์
ปีการศึกษา 2568
ลิขสิทธิ์ของมหาวิทยาลัยธรรมศาสตร์

การพยากรณ์ทิศทางราคาหุ้นด้วย LSTM และ Attention Mechanism
ร่วมกับ Explainable AI: การเปรียบเทียบ SHAP กับ Pearson
Correlation

โดย

นายอรรณพ แซ่เงิน
นายวชิรวิทย์ แก้วแดง

โครงการพิเศษนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
วิทยาศาสตรบัณฑิต
สาขาวิชาวิทยาการคอมพิวเตอร์
คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์
ปีการศึกษา 2568
ลิขสิทธิ์ของมหาวิทยาลัยธรรมศาสตร์

STOCK PRICE DIRECTION PREDICTION USING LSTM + ATTENTION
MECHANISM WITH EXPLAINABLE AI (SHAP VS CORRELATION)

BY

MR TUMRONG SAECHOEN
MR WACHIRAWIT KEAWDAENG

A FINAL-YEAR PROJECT REPORT SUBMITTED IN PARTIAL FULFILLMENT
OF THE REQUIREMENTS FOR THE DEGREE OF BACHELOR OF SCIENCE
COMPUTER SCIENCE
FACULTY OF SCIENCE AND TECHNOLOGY
THAMMASAT UNIVERSITY
ACADEMIC YEAR 2025
COPYRIGHT OF THAMMASAT UNIVERSITY

มหาวิทยาลัยธรรมศาสตร์
คณะวิทยาศาสตร์และเทคโนโลยี

รายงานโครงงานพิเศษ

ของ

นายอรรณพ แซ่ฉิน
นายวชิรวิทย์ แก้วแดง

เรื่อง

การพยากรณ์ทิศทางราคาหุ้นด้วย LSTM และ Attention Mechanism ร่วมกับ Explainable
AI: การเปรียบเทียบ SHAP กับ Pearson Correlation

ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
เมื่อ วันที่ 22 พฤษภาคม พ.ศ. 2568

อาจารย์ที่ปรึกษา



(ผศ.ดร.วิรัตน์ จาริวงษ์ไพบูลย์)

กรรมการสอบโครงงานพิเศษ



(ผศ.ดร.ธำปนา บุญชู)

กรรมการสอบโครงงานพิเศษ



(ผศ.ดร.เสาวลักษณ์ วรรณภา)

มหาวิทยาลัยธรรมศาสตร์
คณะวิทยาศาสตร์และเทคโนโลยี

รายงานโครงงานพิเศษ

ของ

นายจรัส แซ่ฉิน
นายชวิทย์ แก้วแดง
เรื่อง

การพยากรณ์ทิศทางราคาหุ้นด้วย LSTM และ Attention Mechanism ร่วมกับ Explainable AI:
การเปรียบเทียบ SHAP กับ Pearson Correlation


ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
เมื่อ วันที่ 22 พฤษภาคม พ.ศ. 2568

อาจารย์ที่ปรึกษา




(ผศ.ดร.วิรัตน์ จาริวงค์ไพบูลย์)

กรรมการสอบโครงงานพิเศษ



(ผศ.ดร.ธำปนา บุญชู)

กรรมการสอบโครงงานพิเศษ



(ผศ.ดร.เสาวลักษณ์ วรรณภา)

หัวข้อโครงการพิเศษ

การพยากรณ์ทิศทางราคาหุ้นด้วย LSTM และ
Attention Mechanism ร่วมกับ Explainable AI: การ
เปรียบเทียบ SHAP กับ Pearson Correlation

ชื่อผู้เขียน

นายธำรง แซ่เงิน

ชื่อผู้เขียน

นายวชิรวิทย์ แก้วแดง

ชื่อปริญญา

วิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

สาขาวิชา/คณะ/มหาวิทยาลัย

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์และเทคโนโลยี

มหาวิทยาลัยธรรมศาสตร์

อาจารย์ที่ปรึกษาโครงการพิเศษ

ผศ.ดร.วิรัตน์ จาริวงศ์ไพบูลย์

ปีการศึกษา

2568

บทคัดย่อ

โครงการนี้มุ่งศึกษาและเปรียบเทียบประสิทธิภาพของการคัดเลือก Feature สำหรับการพยากรณ์ทิศทางราคาหุ้นในตลาดหลักทรัพย์สหรัฐอเมริกา ระหว่างวิธี Pearson Correlation และวิธี SHAP (SHapley Additive exPlanations) ซึ่งเป็นส่วนหนึ่งของแนวคิด Explainable AI (XAI) โดยใช้โมเดล LSTM เป็นแกนหลักในการพยากรณ์ทิศทางราคาหุ้นรายวัน พร้อมทั้งเปรียบเทียบกับโมเดล Baseline ได้แก่ Random Forest และ Logistic Regression เพื่อตรวจสอบความสอดคล้องของ Feature Importance ข้ามโมเดล (Cross-model Consistency) ข้อมูลที่ใช้ประกอบด้วยราคาหุ้นรายวันของ 10 หุ้นใน 5 ภาคอุตสาหกรรม ได้แก่ NVDA, TSLA (เทคโนโลยี), JNJ, UNH (การแพทย์), XOM, CVX (พลังงาน), JPM, GS (การเงิน), AMZN, COST (ผู้บริโภค) ตั้งแต่เดือนมกราคม ค.ศ. 2020 ถึงเมษายน ค.ศ. 2025 รวมประมาณ 1,300 วันทำการ โดยสร้าง Feature ทั้งหมด 27 ตัว แบ่งเป็น Price-based 6 ตัว, Trend 6 ตัว, Momentum 6 ตัว, Volume 4 ตัว และ Market-wide 5 ตัว (รวม Bond Yield และ S&P 500) ตัวแปรเป้าหมายคือ 3-day Forward Return แบบ Binary Classification (ขึ้น/ลง) โดยแบ่ง Train/Test แบบ Time-ordered 80/20

ผลการทดลองพบว่า Correlation และ SHAP ให้การจัดลำดับความสำคัญของ Feature ที่แตกต่างกันอย่างมีนัยสำคัญ โดยเฉลี่ย 5-12 อันดับต่อ Feature โดย Volatility_5d มีความแตกต่างสูงสุด เนื่องจาก Correlation วัดได้เพียง Linear Relationship ขณะที่ SHAP สามารถจับ Non-linear Effect ได้ ที่น่าสังเกตคือ Bond_yield ปรากฏใน SHAP Top-5 ของ 8 จาก 10 หุ้น แต่ถูก Pearson Correlation จัดอันดับต่ำ ซึ่งพิสูจน์ว่า SHAP สามารถจับผลกระทบเชิง Macro-economic แบบ Non-linear ได้ OBV และ Bond_yield เป็น Feature ที่มีความสำคัญสูงอย่าง Consistent ข้ามทั้ง 3 Models (LSTM, Random Forest, Logistic Regression) และการเพิ่ม VIX Sentiment ช่วยเพิ่มความแม่นยำของโมเดลได้ใน 6 จาก 10 หุ้น โดย VIX_change มี SHAP Importance สูงสุดในกลุ่ม VIX Features

คุณค่าที่แท้จริงของ SHAP ในโครงการนี้ไม่ได้อยู่ที่การชนะ Correlation ในด้าน Model Performance เท่านั้น แต่อยู่ที่ความสามารถในการอธิบายการทำนายในระดับรายวัน (Local Explanation) ซึ่ง Correlation ไม่สามารถทำได้เลย และการที่ SHAP สามารถจับ Feature

ที่มี Non-linear Effect เช่น Volatility_5d ซึ่ง Correlation มองข้ามไป โครงการนี้จึงเป็นพื้นฐานสำคัญของระบบวิเคราะห์การลงทุนที่เชื่อถือได้และตีความได้ในอนาคต

คำสำคัญ: LSTM, Attention Mechanism, SHAP, Pearson Correlation, ปัญญาประดิษฐ์ที่อธิบายได้, การคัดเลือก Feature, การพยากรณ์ทิศทางราคาหุ้น, VIX, Ensemble

Thesis Title	STOCK PRICE DIRECTION PREDICTION USING LSTM + ATTENTION MECHANISM WITH EXPLAINABLE AI (SHAP VS CORRELATION)
Author	Mr Tumrong Saechoen
Author	Mr Wachirawit Keawdaeng
Degree	Bachelor of Science
Major Field/Faculty/University	Computer Science Faculty of Science and Technology Thammasat University
Project Advisor	Assistant Professor, Ph.D. Wirat Jareevongpiboon
Academic Years	2025

ABSTRACT

This project investigates and compares the effectiveness of two feature importance methods—Pearson Correlation and SHAP (SHapley Additive exPlanations)—for next-day stock price direction forecasting in the U.S. equity market. An LSTM model serves as the primary predictor for binary return classification, complemented by baseline models including Random Forest and Logistic Regression to verify cross-model consistency of feature importance.

The dataset covers 10 stocks across five sectors: NVDA and TSLA (Technology), JNJ and UNH (Healthcare), XOM and CVX (Energy), JPM and GS (Finance), and AMZN and COST (Consumer), spanning January 2020 to April 2025 (approximately 1,300 trading days). A total of 27 features were engineered across five groups: Price-based (6), Trend (6), Momentum (6), Volume (4), and Market-wide (5, including S&P 500 and Bond Yield). The target variable is the 3-day forward return binary direction (Up/Down) with an 80/20 time-ordered train/test split. The LSTM model uses a 3-layer architecture with Attention Mechanism (hidden_size=128), a sequence length of 60 days, Focal Loss (gamma=2), and early stopping monitored on F1-Score.

Results demonstrate that Pearson Correlation and SHAP produce substantially different feature rankings, with an average rank disagreement of 5–12 positions per feature. Notably, Bond_yield appears in the SHAP Top-5 for 8 out of 10 stocks but is consistently ranked low by Pearson Correlation, proving that SHAP captures non-linear macro-economic effects that Correlation misses. Volatility_5d exhibited the highest rank disagreement. OBV and Bond_yield emerged as consistently important features across all three models (LSTM, Random Forest, Logistic Regression) and all stocks, confirming their model-agnostic importance. Incorporating VIX sentiment improved accuracy in 6 out of 10 stocks, with VIX_change having the highest SHAP importance among VIX features. The ensemble model (soft voting with optimal threshold) outperformed individual models in 7 out

of 10 stocks, achieving best F1 scores of JPM 0.754, UNH 0.750, and COST 0.750, with an average F1 of approximately 0.71 across all stocks.

Keywords: LSTM, Attention Mechanism, SHAP, Pearson Correlation, Explainable AI, Feature Selection, Stock Prediction, VIX, Ensemble

กิตติกรรมประกาศ

โครงการฉบับนี้สำเร็จสมบูรณ์ได้ด้วยการสนับสนุน คำแนะนำ และความเอาใจใส่จากหลายฝ่าย ผู้จัดทำขอกราบขอบพระคุณอาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ ดร.วิรัตน์ จาริวงศ์ ไพบุลย์ ที่ให้คำปรึกษาอย่างใกล้ชิด ให้คำแนะนำเชิงวิชาการ และช่วยชี้แนะแนวทางที่ถูกต้องตลอดกระบวนการทำโครงการ

ผู้จัดทำขอขอบคุณคณะกรรมการสอบโครงการพิเศษ ผู้ช่วยศาสตราจารย์ ดร.ธำปนา บุญชู และผู้ช่วยศาสตราจารย์ ดร.เสาวลักษณ์ วรรณภา ที่กรุณาสละเวลาตรวจสอบและให้ข้อเสนอแนะอันเป็นประโยชน์ต่อการปรับปรุงงานวิจัยนี้

ผู้จัดทำขอขอบคุณคณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์ ที่สนับสนุนทรัพยากรและโอกาสในการดำเนินโครงการ รวมถึงขอขอบคุณเพื่อนร่วมโครงการ ที่ร่วมแรงร่วมใจกันพัฒนาระบบจนสำเร็จ นอกจากนี้ ผู้จัดทำขอขอบคุณครอบครัวและเพื่อนทุกคนที่คอยให้กำลังใจมาโดยตลอด

นายวิชิตวิทย์ แก้วแดง

นายธำรง แซ่เงิน

สารบัญ

	หน้า
บทคัดย่อ	2
ABSTRACT	5
กิตติกรรมประกาศ	7
สารบัญ	8
สารบัญตาราง	11
สารบัญภาพ	12
รายการสัญลักษณ์และคำย่อ	14
บทที่ 1	18
บทนำ	18
1.1 ความเป็นมาและความสำคัญของโครงการ	18
1.2 วัตถุประสงค์	18
1.3 ขอบเขตของโครงการ	19
1.4 ประโยชน์ของโครงการ	20
บทที่ 2 วรรณกรรมและงานวิจัยที่เกี่ยวข้อง	21
2.1 แนวคิดทฤษฎีที่เกี่ยวข้อง	21
2.1.1 Pearson Correlation และการคัดเลือก Feature (Feature Selection via Correlation)	21
2.1.2 SHAP (SHapley Additive exPlanations) และ Explainable AI	21

	(9)
2.1.3	LSTM (Long Short-Term Memory) และ Technical Indicators 22
2.1.4	Technical Indicators (ตัวชี้วัดทางเทคนิค) 23
2.1.5	Market-wide Features และ VIX Index (ดัชนีตลาดและดัชนีความกลัว) 24
2.2	งานวิจัยที่เกี่ยวข้อง 25
2.2.1	งานวิจัยเรื่อง “การคาดการณ์ทิศทางของหุ้นไทยโดยใช้NLP(Sentiment Analysis) วิเคราะห์จากหัวข้อข่าวของหุ้น” 25
2.2.2	งานวิจัยเรื่อง “Pearson Correlation Coefficient-Based Performance Enhancement of Broad Learning System for Stock Price Prediction” (Li et al., 2022) 29
2.2.3	งานวิจัยเรื่อง “Explainable Stock Prices Prediction from Financial News Articles using Sentiment Analysis” (Gite et al., 2021) 29
2.2.4	งานวิจัยเรื่อง “Significance of Predictors: Revisiting Stock Return Predictions using Explainable AI” (Annals of Operations Research, 2025) 30
2.3	เปรียบเทียบงานวิจัยและแนวทางของโครงการ 31
บทที่ 3	33
วิธีการวิจัย	33
3.1	ภาพรวมของโครงการ 33
3.2	การรวบรวมข้อมูล (Data Collection) 34
3.3	Feature Engineering 34
3.4	โมเดลที่ใช้ในโครงการ (Model Architecture) 35
3.5	การออกแบบการทดลอง (Experiment Design) 36
3.6	เกณฑ์การวัดผล (Evaluation Metrics) 36
บทที่ 4	ผลการทดลองและการวิเคราะห์ 38
4.1	ผลการรวบรวมข้อมูล 38

4.2	ผลการทำงาน Feature Engineering	40
4.3	ผลการเทรนโมเดล LSTM ทุกหุ้น+หา Optimal Threshold	42
4.4	ผลการเปรียบเทียบ Pearson Correlation กับ SHAP	44
4.5	ผลทดสอบ Feature Quality ของ SHAP และ Pearson Correlation ด้วย F1-Score	49
4.6	ผลการวิเคราะห์ Cross-model SHAP Consistency	50
4.7	ผลการเพิ่ม VIX Sentiment Features	53
4.8	การใช้ Ensemble Model	54
4.9	ผลการวิเคราะห์ตาม Sector (Sector-level SHAP Analysis)	55
4.10	สรุปผลการทดลองทั้งหมด	56
บทที่ 5		57
สรุป		57
5.1	สรุปผลการวิจัย	57
5.2	ข้อจำกัดของโครงการ	57
5.3	แนวทางในอนาคต (Future Work)	58
รายการอ้างอิง		59
ภาคผนวก		61
ภาคผนวก ก.	รายละเอียด Features ที่ใช้ในโครงการ	62
ภาคผนวก ข.	ผลการทดลอง SHAP Feature Importance รายหุ้น	65
ภาคผนวก ค.	รายละเอียด Hyperparameters และ Environment	66

สารบัญตาราง

	หน้า
ตารางที่ 2.1 แสดงการเปรียบเทียบงานวิจัยที่เกี่ยวข้องกับแนวทางของโครงงานนี้ในด้านข้อมูล โมเดล วิธีคัดเลือก Feature และการใช้ Explainable AI	30
ตารางที่ 4.2 ตารางแสดง accuracy ของโมเดลหลังจากเพิ่ม VIX features	53
ตารางที่ ก.1 รายละเอียด Features ทั้ง 27 ตัวที่ใช้ในการ Train โมเดล	62
ตารางที่ ข.1 สรุป SHAP Top-5 Feature Importance ของแต่ละหุ้นจากโมเดล LSTM + Attention Mechanism	65
ตารางที่ ค.1 Hyperparameters ของโมเดล LSTM + Attention Mechanism	66
ตารางที่ ค.2 Software และ Hardware Environment	67

สารบัญภาพ

หน้า

ภาพที่ 2.1 โครงสร้างโมเดลของงานวิจัย การคาดการณ์ทิศทางของหุ้นไทยโดยใช้ NLP (Sentiment Analysis) วิเคราะห์จากหัวข้อข่าวของหุ้น

32

ภาพที่ 2.2 ตัวอย่างข้อมูลที่ได้จากการทำ Web Scraping 33

ภาพที่ 2.3 ตัวอย่าง Data Frame หลังจาก Data Preparation 34

ภาพที่ 2.4 ตารางสรุปประสิทธิภาพของโมเดล 34

ภาพที่ 4.1.1 ผลการรวบรวมข้อมูลจาก yfinance 38

ภาพที่ 4.1.2 ตัวอย่างข้อมูลราคาหุ้น NVIDIA (NVDA) ที่รวบรวมจาก yfinance

38

ภาพที่ 4.1.3 ตัวอย่างข้อมูลดัชนี S&P 500 (^GSPC) ที่รวบรวมจาก yfinance 39

ภาพที่ 4.1.4 ตัวอย่างข้อมูล US 10-Year Treasury Yield (^TNX) ที่รวบรวมจาก yfinance

39

ภาพที่ 4.1.5 ตัวอย่างข้อมูล CBOE Volatility Index (^VIX) ที่รวบรวมจาก yfinance 40

ภาพที่ 4.2.1 ผลลัพธ์จากการทำ Feature Engineering 40

ภาพที่ 4.2.2 Feature ด้าน Return และ Volatility ที่ได้จาก Feature Engineering

41

ภาพที่ 4.2.3 Feature ด้าน Moving Average, RSI และ MACD ที่ได้จาก Feature Engineering

41

ภาพที่ 4.2.4 Feature ด้าน Stochastic Oscillator, Volume และ OBV ที่ได้จาก Feature Engineering 41

ภาพที่ 4.2.5 Feature ด้าน Market-wide (S&P500, Bond Yield) และ Target ที่ได้จาก Feature Engineering 41

ภาพที่ 4.3.1 ผลลัพธ์หลังจากเทรนโมเดล LSTM ของหุ้น 10 ตัว (1) 42

ภาพที่ 4.3.2 ผลลัพธ์หลังจากเทรนโมเดล LSTM ของหุ้น 10 ตัว (2) 43

ภาพที่ 4.3.3 ผลลัพธ์หลังจากเทรนโมเดล LSTM ของหุ้น 10 ตัว (3) 44

ภาพที่ 4.4.1 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (1)

45

ภาพที่ 4.4.2 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (2)	45
ภาพที่ 4.4.3 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (3)	46
ภาพที่ 4.4.4 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (4)	46
ภาพที่ 4.4.5 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (5)	47
ภาพที่ 4.4.6 กราฟแสดง feature rank disagreement ระหว่าง SHAP และ Pearson Correlation heatmap (กราฟด้านซ้าย) กราฟแท่ง (กราฟด้านขวา)	47
ภาพที่ 4.4.7 ตัวอย่าง Local SHAP Explanation ของหุ้น NVDA 5 วัน	48
ภาพที่ 4.4.8 Feature ranking ของ OBV ทั้งสามโมเดล	49
ภาพที่ 4.4.9 Feature ranking ของ bond yield	49
ภาพที่ 4.5.1 กราฟแสดง accuracy ของโมเดล LSTM ระหว่าง SHAP Top-10 vs Pearson Correlation Top-10	50
ภาพที่ 4.6.1 กราฟแสดง SHAP feature importance ของ 3 โมเดล (1)	50
ภาพที่ 4.6.2 กราฟแสดง SHAP feature importance ของ 3 โมเดล (2)	51
ภาพที่ 4.6.3 กราฟแสดง SHAP feature importance ของ 3 โมเดล (3)	51
ภาพที่ 4.6.4 กราฟแสดง SHAP feature importance ของ 3 โมเดล (4)	52
ภาพที่ 4.6.5 กราฟแสดง SHAP feature importance ของ 3 โมเดล (5)	52
ภาพที่ 4.7.1 กราฟแท่งแสดง accuracy ของโมเดล (กราฟด้านซ้าย) heatmap แสดง SHAP importance ของ VIX features (กราฟด้านขวา)	54
ภาพที่ 4.8.1 เปรียบเทียบ Ensemble Model กับ โมเดลอื่นๆ	55
ภาพที่ 4.9.1 กราฟแสดง SHAP importance ของ feature ตาม sector	56
ภาพที่ 4.10.1 สรุปผล F1-Score ของแต่ละหุ้นทั้ง 3 โมเดล พร้อมระบุ Best Model	56
ภาพที่ 4.10.2 สรุปผลการทดลองทั้งหมด (Accuracy, F1-Score ของแต่ละ Model และหุ้น)	56

รายการสัญลักษณ์และคำย่อ

สัญลักษณ์/คำย่อ	คำเต็ม/คำจำกัดความ
AI	Artificial Intelligence — ปัญญาประดิษฐ์
XAI	Explainable Artificial Intelligence — ปัญญาประดิษฐ์ที่อธิบายได้
SHAP	SHapley Additive exPlanations — เทคนิควัดความสำคัญของ Feature โดยอ้างอิงทฤษฎีเกม
LSTM	Long Short-Term Memory — โครงข่ายประสาทเทียมแบบ Recurrent สำหรับข้อมูล Sequential
RF	Random Forest — โมเดล Machine Learning แบบ Ensemble ใช้ Decision Tree หลายต้น
LR	Logistic Regression — โมเดล Classification เชิงเส้นพื้นฐาน
ML	Machine Learning — การเรียนรู้ของเครื่องจักร
DL	Deep Learning — การเรียนรู้เชิงลึก
RNN	Recurrent Neural Network — โครงข่ายประสาทเทียมแบบวนซ้ำ
AUC	Area Under the Curve — พื้นที่ใต้กราฟ ROC ใช้วัดประสิทธิภาพโมเดล
ROC	Receiver Operating Characteristic — กราฟวัดความสามารถในการจำแนกสัญญาณ

F1	F1-Score — ค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall
OHLCV	Open, High, Low, Close, Volume — ข้อมูลราคาหุ้นรายวัน 5 ตัวแปร
VIX	CBOE Volatility Index — ดัชนีความผันผวนที่ตลาดคาดการณ์ล่วงหน้า ใช้เป็น Market Sentiment
MA	Moving Average — ค่าเฉลี่ยเคลื่อนที่
EMA	Exponential Moving Average — ค่าเฉลี่ยเคลื่อนที่แบบถ่วงน้ำหนักเอ็กซ์โพเนนเชียล
RSI	Relative Strength Index — ดัชนีวัดความแรงสัมพัทธ์ของราคา
MACD	Moving Average Convergence Divergence — ตัวชี้วัด Momentum จากผลต่างของ EMA
OBV	On-Balance Volume — ตัวชี้วัด Volume สะสมตามทิศทางราคา
GPU	Graphics Processing Unit — หน่วยประมวลผลกราฟิก ใช้เร่งการ Train โมเดล
CUDA	Compute Unified Device Architecture — แพลตฟอร์มของ NVIDIA สำหรับ GPU Computing
API	Application Programming Interface — ส่วนต่อประสานโปรแกรม
NASDAQ	National Association of Securities Dealers Automated Quotations — ตลาดหลักทรัพย์สหรัฐฯ

JPM	JPMorgan Chase & Co. — บริษัท การเงินการธนาคารสหรัฐฯ กลุ่มภาคการเงิน
TSLA	Tesla Inc. — บริษัทผลิตรถยนต์ไฟฟ้า และพลังงาน กลุ่มภาคเทคโนโลยี
NVDA	NVIDIA Corporation — บริษัท GPU และ AI กลุ่มภาคเทคโนโลยี
GS	The Goldman Sachs Group, Inc. — บริษัทธนาคารเพื่อการลงทุน กลุ่มภาคการเงิน
JNJ	Johnson & Johnson — บริษัท การแพทย์และเวชภัณฑ์ กลุ่มภาคการแพทย์
UNH	UnitedHealth Group Incorporated — บริษัทประกันสุขภาพ กลุ่มภาคการแพทย์
XOM	Exxon Mobil Corporation — บริษัท พลังงานและน้ำมัน กลุ่มภาคพลังงาน
CVX	Chevron Corporation — บริษัท พลังงานและน้ำมัน กลุ่มภาคพลังงาน
AMZN	Amazon.com, Inc. — บริษัท E- commerce และ Cloud Computing กลุ่มภาคผู้บริโภค
COST	Costco Wholesale Corporation — บริษัทค้าปลีก กลุ่มภาคผู้บริโภค
S&P 500	Standard & Poor's 500 — ดัชนีหุ้น สหรัฐฯ 500 บริษัทขนาดใหญ่ ใช้เป็น Market-wide Feature
Bond Yield	อัตราผลตอบแทนพันธบัตร (US 10-Year Treasury Yield) — ใช้เป็น Market-wide Feature วัด นโยบายดอกเบี้ยและความเสี่ยงมหภาค

Focal Loss	ฟังก์ชัน Loss ที่ออกแบบมาจัดการกับ Class Imbalance โดยให้น้ำหนักมากกับตัวอย่างที่ยากในการจำแนก ($\gamma=2$ ในโครงงานนี้)
Attention Mechanism	กลไก Attention Mechanism ที่ช่วยให้โมเดลเรียนรู้ความสำคัญของแต่ละ Time Step ในลำดับข้อมูล ใช้ร่วมกับ LSTM ในโครงงานนี้
Ensemble	การรวมผลทำนายจากหลาย Model เพื่อลด Bias และเพิ่มความแม่นยำ
Threshold	ค่าที่ใช้ตัดสินใจว่าจะ predict class 0 หรือ 1 ปรับให้ F1 สูงสุดต่อหุ่น

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของโครงการ

ตลาดหลักทรัพย์สหรัฐอเมริกาเป็นกลไกสำคัญของระบบเศรษฐกิจโลก ราคาหุ้นได้รับอิทธิพลจากปัจจัยหลากหลายทั้งเชิงปริมาณ เช่น ข้อมูลทางเทคนิคและดัชนีตลาด และเชิงคุณภาพ เช่น ความผันผวนของดอกเบี้ยและอารมณ์ของนักลงทุน การพยากรณ์ทิศทางราคาหุ้นอย่างแม่นยำจึงเป็นองค์ประกอบสำคัญต่อการตัดสินใจลงทุน

ปัญหาสำคัญประการหนึ่งในการสร้างโมเดลพยากรณ์คือการคัดเลือก Feature ที่เหมาะสม วิธีดั้งเดิมที่นิยมใช้คือ Pearson Correlation ซึ่งวัดความสัมพันธ์เชิงเส้นระหว่าง Feature กับ Target อย่างไรก็ตาม วิธีดังกล่าวมีข้อจำกัดสำคัญคือไม่สามารถจับ Non-linear Relationship และ Interaction Effect ระหว่าง Feature ได้

เทคนิค SHAP (SHapley Additive exPlanations) ซึ่งเป็นส่วนหนึ่งของแนวคิด Explainable AI (XAI) สามารถวัดความสำคัญของแต่ละ Feature ต่อผลการทำนายได้อย่างครอบคลุมกว่า เนื่องจากคำนึงถึง Non-linear Effect ด้วย โครงการนี้จึงมุ่งเปรียบเทียบประสิทธิภาพของ Correlation และ SHAP ในการคัดเลือก Feature โดยใช้ LSTM + Attention Mechanism เป็นโมเดลหลัก บนข้อมูลหุ้น 10 ตัวจาก 5 Sector ในตลาด NASDAQ ช่วงปี ค.ศ. 2020-2025

1.2 วัตถุประสงค์

เปรียบเทียบ Feature Ranking ระหว่าง Pearson Correlation และ SHAP ในบริบทการพยากรณ์ทิศทางราคาหุ้น

ทดสอบว่า Feature ที่ SHAP คัดเลือก (SHAP Top-10) ให้ F1-Score สูงกว่า Feature ที่ Correlation คัดเลือก (Corr Top-10) หรือไม่

ตรวจสอบความสอดคล้องของ SHAP Feature Importance ข้าม 3 Models (LSTM, Random Forest, Logistic Regression) เพื่อยืนยัน Feature ที่สำคัญในเชิง Model-agnostic

ศึกษาผลของการเพิ่ม VIX Index เป็น Market Sentiment Proxy ต่อความแม่นยำของโมเดลและ SHAP Feature Importance

สร้าง Ensemble Model (LSTM + RF + LR Soft Voting พร้อม Optimal Threshold) เพื่อเพิ่มประสิทธิภาพการพยากรณ์ และวิเคราะห์ SHAP ในระดับ Sector เพื่อทำความเข้าใจความสำคัญของ Feature ในแต่ละภาคอุตสาหกรรม

1.3 ขอบเขตของโครงการ

ศึกษาหุ้นในประเทศสหรัฐอเมริกา เช่น 10 หุ้นใน 5 ภาคอุตสาหกรรม: NVDA, TSLA (Technology), JNJ, UNH (Healthcare), XOM, CVX (Energy), JPM, GS (Finance), AMZN, COST (Consumer) ตลาดหลักทรัพย์สหรัฐฯ

ข้อมูลที่ใช้ประกอบด้วย

ข้อมูลราคาหุ้นรายวัน (OHLCV) ดึงผ่าน yfinance API

Features ทั้งหมด 27 ตัว แบ่งเป็น 5 กลุ่ม: Price-based (6), Trend (6), Momentum (6), Volume (4), Market-wide (5 รวม S&P 500 และ Bond Yield)

VIX Index และ VIX-derived Features 5 ตัว (VIX, VIX_change, VIX_MA5, VIX_MA20, Fear_level) เป็น Market Sentiment Proxy

โมเดลหลัก: LSTM + Attention Mechanism (3 layers, hidden_size=128, Focal Loss, Early Stopping บน F1); โมเดล Baseline: Random Forest (n=200) และ Logistic Regression; Ensemble: Soft Voting พร้อม Optimal Threshold

ประเมินผลในกรอบเวลา 5 ปี (มกราคม 2020 – เมษายน 2025) ประมาณ 1,300 วันทำการ แบ่ง Train/Test แบบ Time-ordered 80/20 และตัวแปรเป้าหมาย: 3-day Forward Return (ขึ้น/ลง)

1.4 ประโยชน์ของโครงการ

เข้าใจข้อจำกัดของ Pearson Correlation ในการคัดเลือก Feature สำหรับข้อมูลตลาดหุ้นที่มี Non-linear Pattern เข้าใจตัวแปรที่มีผลสำคัญต่อทิศทางราคาผ่านเครื่องมือ XAI

เห็นคุณค่าของ SHAP ในการอธิบายโมเดลทั้งระดับ Global Explanation และ Local Explanation รายวัน

มีระบบต้นแบบสำหรับพยากรณ์ทิศทางราคาหุ้นที่สามารถตีความได้และนำไปใช้งานได้จริง

เป็นพื้นฐานสำหรับการพัฒนาระบบสนับสนุนการตัดสินใจลงทุนในอนาคตที่รวม FinBERT และ Fundamental Data

บทที่ 2

วรรณกรรมและงานวิจัยที่เกี่ยวข้อง

2.1 แนวคิดทฤษฎีที่เกี่ยวข้อง

2.1.1 Pearson Correlation และการคัดเลือก Feature (Feature Selection via Correlation)

Pearson Correlation คือการวัดความสัมพันธ์เชิงเส้นระหว่างตัวแปรสองตัว มีค่าอยู่ในช่วง -1 ถึง +1 คำนวณได้จากสูตร

$$r(X, Y) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{[\sum(x_i - \bar{x})^2 \cdot \sum(y_i - \bar{y})^2]}}$$

โดยที่ X และ Y คือตัวแปรสองตัวที่ต้องการวัดความสัมพันธ์, x_i และ y_i คือค่าของตัวอย่างที่ i, $\bar{x}$ และ $\bar{y}$ คือค่าเฉลี่ยของ X และ Y ตามลำดับ, และ n คือจำนวนตัวอย่างทั้งหมด โดยค่าใกล้ +1 หมายความว่าตัวแปรสองตัวเคลื่อนไหวในทิศทางเดียวกัน และค่าใกล้ -1 หมายความว่าเคลื่อนไหวสวนทางกัน ในการคัดเลือก Feature สำหรับโมเดล Machine Learning นิยมใช้ Absolute Pearson Correlation ระหว่าง Feature แต่ละตัวกับ Target Variable เพื่อจัดอันดับความสำคัญ อย่างไรก็ตาม ข้อจำกัดสำคัญของวิธีนี้คือวัดได้เพียง Linear Relationship เท่านั้น ไม่สามารถจับความสัมพันธ์แบบ Non-linear หรือ Interaction Effect ระหว่าง Feature หลายตัวได้ รวมถึงไม่สามารถอธิบายว่า Feature นั้น "ดัน" การทำนายขึ้นหรือลงได้อย่างไรในแต่ละกรณี

2.1.2 SHAP (SHapley Additive exPlanations) และ Explainable AI

SHAP (SHapley Additive exPlanations) คือเทคนิคใน Explainable AI ที่อธิบายความสำคัญของแต่ละ Feature ต่อการทำนายของโมเดล โดยอ้างอิงจากทฤษฎี Shapley Value ในทฤษฎีเกม ซึ่งกระจาย "เครดิต" ของผลลัพธ์ให้กับ Feature แต่ละตัวอย่างยุติธรรมโดยพิจารณาทุก Combination ที่เป็นไปได้ SHAP มีคุณสมบัติสำคัญ 3 ประการ ได้แก่ (1) Local Accuracy — ผลรวมของ SHAP Values ทุก Feature เท่ากับผลต่างของการทำนายกับ Baseline

(2) Consistency — Feature ที่มีผลต่อโมเดลมากกว่าจะได้รับ SHAP Value สูงกว่าเสมอ และ (3) Missingness — Feature ที่ไม่มีผลจะได้ SHAP Value เป็นศูนย์ SHAP สามารถแสดงผลได้ทั้งระดับ Global Explanation (ภาพรวมว่า Feature ใดสำคัญที่สุดข้ามทุกตัวอย่าง) และ Local Explanation (ว่าทำไมโมเดลถึงทำนายแบบนั้นสำหรับตัวอย่างหนึ่งๆ โดยเฉพาะ) และที่สำคัญคือใช้ได้กับโมเดลทุกประเภท (Model-agnostic) รวมถึง LSTM ด้วย สูตรของ SHAP Value สำหรับ Feature i คำนวณจาก Shapley Value ดังนี้

$$\phi_i = \sum \frac{|S|!(|F|-|S|-1)!}{|F|!} \cdot [f(S \cup \{i\}) - f(S)]$$

โดยที่ F คือเซตของ Feature ทั้งหมด, S คือเซตย่อยของ Feature ที่ไม่รวม i , $f(S)$ คือค่าที่โมเดลทำนายเมื่อใช้เฉพาะ Feature ใน S , $f(S \cup \{i\})$ คือค่าที่โมเดลทำนายเมื่อเพิ่ม Feature i เข้าไป และการหาผลรวมครอบคลุม Feature Subset ทุกเซตที่เป็นไปได้ (Lundberg & Lee, 2017)

2.1.3 LSTM (Long Short-Term Memory) และ Technical Indicators

โครงข่าย RNN แบบดั้งเดิมประสบปัญหา Vanishing Gradient Problem กล่าวคือ Gradient ที่ใช้ปรับ Weight จะลดลงเรื่อยๆ เมื่อ Backpropagate ผ่าน Time Step จำนวนมาก ทำให้โมเดลไม่สามารถเรียนรู้ความสัมพันธ์ระยะยาวได้ (Hochreiter & Schmidhuber, 1997) Hochreiter และ Schmidhuber จึงเสนอ LSTM เพื่อแก้ปัญหาดังกล่าวโดยใช้ Cell State ที่ส่งข้อมูลผ่านเวลาโดยมีการสูญเสียที่น้อยที่สุด

LSTM (Long Short-Term Memory) คือโครงข่ายประสาทเทียมแบบ Recurrent Neural Network (RNN) ที่ออกแบบมาเพื่อเรียนรู้ความสัมพันธ์ระยะยาวใน Sequential Data ผ่าน Gate Mechanism 3 ประเภท โดยมีสมการหลักดังนี้

$$\text{Forget Gate: } f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$\text{Input Gate: } i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

Candidate: $C_t = \tanh(W_c \cdot [h_{t-1}, x_t] + bc)$

Cell State: $C_t = f_t \odot C_{t-1} + i_t \odot C_t$

Output Gate: $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + bo)$

Hidden State: $h_t = o_t \odot \tanh(C_t)$

โดยที่ x_t คือ Input ณ เวลา t , h_{t-1} คือ Hidden State จากขั้นก่อนหน้า, C_t คือ Cell State ที่เก็บข้อมูลระยะยาว, W และ b คือ Weight Matrix และ Bias ตามลำดับ, σ คือ Sigmoid Function, $\tanh$ คือ Hyperbolic Tangent Function และ $\odot$ คือการคูณแบบ Element-wise (Hadamard Product) ทำให้ LSTM เหมาะกับข้อมูลราคาหุ้นซึ่งมีลักษณะเป็น Time-series ที่มีความผันผวนสูงและมีความสัมพันธ์ระยะยาวระหว่างวัน Technical Indicators คือ ค่าที่คำนวณได้จากข้อมูลราคาและปริมาณการซื้อขาย เพื่อสรุปพฤติกรรมของตลาดในรูปแบบที่ โมเดลเรียนรู้ได้ง่ายขึ้น โครงการนี้ใช้ Technical Indicators 4 กลุ่มหลัก ได้แก่ Price-based (Return และ Volatility), Trend (Moving Average และ EMA), Momentum (RSI, MACD, Stochastic) และ Volume (OBV, Volume change) รวม 22 Features

2.1.4 Technical Indicators (ตัวชี้วัดทางเทคนิค)

Technical Indicators คือค่าที่คำนวณจากราคาและปริมาณการซื้อขายในอดีต โครงการนี้แบ่งเป็น 4 กลุ่ม ได้แก่

Price-based: Return_1d, Return_3d, Return_5d, Return_10d, Volatility_5d, Volatility_20d — วัดการเปลี่ยนแปลงและความผันผวนของราคา

Trend: MA5, MA20, MA50, EMA12, EMA26, Price_MA20_dist — บอก ทิศทางแนวโน้ม ถ้าราคาสูงกว่า MA แสดงว่าแนวโน้มเป็นขาขึ้น

Momentum: RSI, MACD, MACD_signal, MACD_diff, Stoch_k, Stoch_d — วัดความแรงของการเปลี่ยนแปลง เช่น $RSI > 70$ คือ Overbought, $RSI < 30$ คือ Oversold

RSI (Relative Strength Index):

วัดว่าใน 14 วันที่ผ่านมา วันที่ราคาขึ้นมีน้ำหนักมากแค่ไหนเทียบกับวันที่ลง

RSI > 70 = Overbought ซื้อมากเกินไป → มักมีแรงขายดึงราคาลง

RSI < 30 = Oversold ขายมากเกินไป → มักมีแรงซื้อดันราคาขึ้น

RSI 40–60 = ภาวะปกติ ไม่มีสัญญาณชัดเจน

MACD (Moving Avg Convergence Divergence):

MACD Line = EMA12 – EMA26 (วัดความต่างของ Trend)

Signal Line = EMA9 ของ MACD (Smooth สัญญาณ)

MACD_diff = MACD – Signal (ความแรงของสัญญาณ)

MACD ข้ามเส้น Signal ↑ (Bullish Crossover) → สัญญาณซื้อ ราคา
มักขึ้นต่อ

MACD ข้ามเส้น Signal ↓ (Bearish Crossover) → สัญญาณขาย

Volume: Volume_change, OBV, Volume_MA20, Volume_MA_ratio —
วิเคราะห์ปริมาณการซื้อขาย OBV บวกปริมาณเมื่อราคาขึ้น ลบเมื่อราคาลง

OBV (On-Balance Volume):

OBV_วันนี้ = OBV_เมื่อวาน + Volume (ถ้าราคาขึ้น)

= OBV_เมื่อวาน – Volume (ถ้าราคาลง)

ตัวเลข OBV สัมบูรณ์ไม่สำคัญ สำคัญคือทิศทางขึ้นหรือลง

OBV ขึ้นเรื่อยๆ = Smart Money กำลังสะสมหุ้น → ราคา
ขึ้นตาม

OBV ลงเรื่อยๆ = Distribution → ราคา
มักลง

OBV มักเปลี่ยนทิศทางก่อนราคา → Leading Indicator ที่ดี
ที่สุด

2.1.5 Market-wide Features และ VIX Index (ดัชนีตลาดและดัชนีความกลัว)

Market-wide Features คือตัวแปรที่สะท้อนสถานะตลาดโดยรวม ประกอบด้วย
SP500_return (ผลตอบแทนดัชนี S&P 500 รายวัน), SP500_MA20 (แนวโน้ม 20 วัน),

SP500_vol (ความผันผวน S&P 500), Relative_return (ผลตอบแทนของหุ้นลบด้วย SP500_return บอกว่าหุ้น outperform หรือ underperform ตลาด) และ Bond_yield (อัตราผลตอบแทนพันธบัตรรัฐบาลสหรัฐฯ 10 ปี (^TNX) เมื่อ Bond_yield สูง หุ้น Growth มักลดลง แต่หุ้น Finance มักเพิ่มขึ้น)

เมื่อ VIX สูง (มากกว่า 30) หมายความว่านักลงทุนกังวลและกลัวมาก ตลาดมักผันผวนรุนแรงและราคาหุ้นมักลดลง เมื่อ VIX ต่ำ (น้อยกว่า 15) หมายความว่านักลงทุนมั่นใจและสงบ ตลาดมักเป็นขาขึ้นอย่างค่อยเป็นค่อยไป โครงการนี้ใช้ VIX เป็น Proxy แทน Sentiment ของตลาดโดยรวม แทนที่จะวิเคราะห์ข่าวโดยตรง เพราะ VIX สะท้อน "อารมณ์" ของนักลงทุนทั้งตลาดได้แบบ real-time และดึงข้อมูลได้ฟรีผ่าน yfinance API โดยไม่ต้องใช้โมเดล NLP ซับซ้อน

โครงการสร้าง Features จาก VIX ทั้งหมด 5 ตัว ได้แก่ VIX (ค่าดัชนีรายวัน), VIX_change (การเปลี่ยนแปลง % ต่อวัน), VIX_MA5 (ค่าเฉลี่ย 5 วัน), VIX_MA20 (ค่าเฉลี่ย 20 วัน) และ Fear_level (แบ่งระดับความกลัวเป็น 4 ระดับ: ต่ำกว่า 15 = สงบ, 15-20 = ปกติ, 20-30 = กังวล, มากกว่า 30 = กลัวมาก)

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 งานวิจัยเรื่อง “การคาดการณ์ทิศทางของหุ้นไทยโดยใช้NLP(Sentiment Analysis) วิเคราะห์จากหัวข้อข่าวของหุ้น”

เรียว ศักดิ์ธนะเศรษฐ (2566)

นำเสนองานวิจัยในการพยากรณ์ทิศทางราคาหุ้นไทยโดยใช้ข้อมูลจากหัวข้อข่าวในหุ้นนั้นๆ โดยใช้เทคนิค NLP (Natural Language Processing) ในการวิเคราะห์ความรู้สึกจากข่าว (Sentiment Analysis) ร่วมกับ TF-IDF (Term Frequency-Inverse Document Frequency) เพื่อแปลงข้อความข่าวเป็นตัวเลขสำหรับป้อนเข้าโมเดล Machine Learning

โมเดลที่ใช้ในงานวิจัยนี้ประกอบด้วย SGD-Classifer, XGBoost, K-Nearest Neighbors (KNN), Naive Bayes และ Neural Network


โดยทดลองกับข้อมูลหุ้นไทยในตลาดหลักทรัพย์แห่งประเทศไทย ผลการทดลองพบว่า Neural Network ให้ผลดีที่สุด โดยมี Overall Performance อยู่ที่ 56.88%

ข้อจำกัดสำคัญของงานวิจัยนี้คือการใช้ TF-IDF ซึ่งจับได้เพียง Linear Relationship ระหว่างคำและ Target และไม่มีการนำ Explainable AI มาอธิบายว่าทำไมโมเดลถึงทำนายแบบนั้น

คุณ เรียว ศักดิ์ธนะเศรษฐ ได้ทำวิจัยเกี่ยวกับการใช้ Sentiment Analysis กับหัวข้อข่าวของหุ้นในประเทศไทยโดยหวังว่าจะเป็นเครื่องมือในการประกอบการตัดสินใจลงทุนและเพื่อสำรวจถึงเครื่องมือในการรับมือความซับซ้อนของภาษาไทยและความน่าเชื่อถือของแหล่งข่าวว่าสามารถนำมาใช้ในการพยากรณ์ราคาหุ้นได้มีประสิทธิภาพเป็นอย่างไร

ภาพที่ 3.1

โครงสร้างงานวิจัย



ภาพที่ 2.1 โครงสร้างโมเดลของงานวิจัย การคาดการณ์ทิศทางของหุ้นไทยโดยใช้NLP(Sentiment Analysis) วิเคราะห์จากหัวข้อข่าวของหุ้น

โดยแหล่งของข้อมูลที่น่ามาใช้นั้นประกอบด้วยข้อมูลจาก Web Site, Web Board, Web Page ที่เน้นออกข่าวสารเกี่ยวกับหุ้น เมื่อรวบรวมข้อมูล Raw Data ได้แล้วจากการทำ Web Scraping จะรวบรวมเป็นไฟล์โดยในไฟล์จะประกอบด้วยคอลัมน์ CreateDate, Source, Source_type, Stock, Topic

ภาพที่ 3.2

CreateDate	Source	Source_Type	Stock	Topic
11/7/2023	ข่าวหุ้นธุรกิจ	Website	SKY	SKY หุ้น 500 ล้าน เข้าตลาด SAMCO แลกไลเนอร์ทั้ง "รปภ.-เมมบ้าน"
11/7/2023	ข่าวหุ้นธุรกิจ	Website	STARK	DSI ออกหมายเรียก "เสียเอ" ผู้ต้องหาคดี STARK ลักทรัพย์ "เบงกใหญ่" พยานปล่อยตัว
11/7/2023	ข่าวหุ้นธุรกิจ	Website	BANPU	BANPU-BPP หุ้น 1.60 หมื่นล้าน ชื้อโรงไฟฟ้า "Temple II" สหรัฐ 755 เมกา รับรายได้ทันที
11/7/2023	ข่าวหุ้นธุรกิจ	Website	BPP	BANPU-BPP หุ้น 1.60 หมื่นล้าน ชื้อโรงไฟฟ้า "Temple II" สหรัฐ 755 เมกา รับรายได้ทันที
11/7/2023	ข่าวหุ้นธุรกิจ	Website	SCB	SCB Financial Markets คาดการณ์งบการเงินปี 34.85-35.15 บาท/ดอลลาร์
11/7/2023	Pantip Sinthorn	Webboard	STARK	จากกรณีหุ้น STARK ขาดสินทรัพย์ได้รับความเสียหายเท่าไรละ แล้วเช็คกับการลงทุนระยะการลงหุ้น
11/7/2023	RYT9	Website	BANPU	BANPU-BPP หุ้น 1.6 หมื่นลบ. ชื้อโรงไฟฟ้าฯ Temple II ในสหรัฐ 755 MW...
11/7/2023	RYT9	Website	BPP	BANPU-BPP หุ้น 1.6 หมื่นลบ. ชื้อโรงไฟฟ้าฯ Temple II ในสหรัฐ 755 MW...
11/7/2023	RYT9	Website	STARK	"อภิชาติ" ฟังหกล้านแห่งใน STARK มีผล 10 ก.ค.
11/7/2023	RYT9	Website	SKY	SKY หุ้น 500 ลบ. เทต SAMCO ทรูทักซ์ศึกษาความปลอดภัย-หาความสะอาด
11/7/2023	EfinanceThai	Website	SKY	SKY หุ้น 500 ลบ. เทตโอเวอร์ SAMCO ทรูทักซ์ศึกษาความปลอดภัย
11/7/2023	EfinanceThai	Website	BANPU	BANPU - BPP บิลด์ซื้อโรงไฟฟ้าฯ Temple II ในสหรัฐ มูลค่า 1.6...
11/7/2023	EfinanceThai	Website	BPP	BANPU - BPP บิลด์ซื้อโรงไฟฟ้าฯ Temple II ในสหรัฐ มูลค่า 1.6...
11/7/2023	ข่าวหุ้นธุรกิจ	Website	KTB	จับตา 8 แนวโน้มกำไร Q2 เดือน 6 หมื่นล้าน ยก KTB ท็อปฟิค
11/7/2023	RYT9	Website	ALL	TFEX สรุปปริมาณการซื้อขายกลุ่ม All Futures สิ้นวันที่ 10 ก.ค. 66
11/7/2023	ข่าวหุ้นธุรกิจ	Website	PHG	PHG-ROJNA พันธมิตรธุรกิจ.?
11/7/2023	ข่าวหุ้นธุรกิจ	Website	ROJNA	PHG-ROJNA พันธมิตรธุรกิจ.?
10/7/2023	Pantip Sinthorn	Webboard	HTC	ขอรด HTC ไฟเขียวแลกพาร์จาก 1.00 บาท เป็น 0.05 บาท *****ลักซื้อคนดีใหม่*****การ
10/7/2023	ข่าวหุ้นธุรกิจ	Website	STARK	"อภิชาติ" สืบตักยักกรรมการผู้มีอำนาจลงนาม STARK
10/7/2023	Pantip Sinthorn	Webboard	FNS	มีเอกสาร พิเศษ สืบตักยัก คือ พรวร กับ FNS ... และอิงรต tvl รับปล่องโหลไปตามข้อมูล ไม่ผิดขรับ
10/7/2023	Pantip Sinthorn	Webboard	TVI	มีเอกสาร พิเศษ สืบตักยัก คือ พรวร กับ FNS ... และอิงรต tvl รับปล่องโหลไปตามข้อมูล ไม่ผิดขรับ

ตัวอย่าง Data set จาก Web scraping

ภาพที่ 2.2 ตัวอย่างข้อมูลที่ได้จากการทำ Web Scraping

ในส่วนของการทำ data preparation จะเป็นการ Clean data และ Label data ในส่วนของ Label ถ้ามูลค่าทางตลาดของหุ้นถัดไป 3 วันมีค่ามากกว่าปัจจุบันจะเป็น 1 นอกนั้นเป็น 0 ส่วนของ Clean data จะประกอบด้วยขั้นตอนดังนี้

1. Remove number, Symbol, Emoji
2. Tokenization
3. POS-tagging
4. Remove Stop-words
5. Remove Duplicate word

ขั้นสุดท้ายคือ Feature Extraction คือการเปลี่ยนข้อมูล Text เป็นเวกเตอร์ของตัวเลขโดยใช้ TF-IDF

ภาพที่ 4.3

ตัวอย่าง Tokenized data

Index	CreatedDate	Source	Stock	Topic	TOKENIZED	TOKEN_LENGTH	TREND
214802	2020-12-25 00:00:00	BangkokBusiness	AOT	โฆษณ "air" 5/965 สายการบิน AOT นธ 05/66 นทท...	['โฆษณ', 'air', '5/965', 'สายการบิน', 'AOT', 'นธ', '05/66', 'นทท...']	41	0
239118	2021-09-02 00:00:00	BangkokBusiness	SCM&S	วันเดียว ฝน 0 จุดที่นครราชสีมา 0/1จุดที่นครราชสีมา 1.43 ซม ...	['วันเดียว', 'ฝน', '0', 'จุดที่นครราชสีมา', '0/1จุดที่นครราชสีมา', '1.43', 'ซม ...']	41	0
168598	2019-09-06 13:26:15	Pattia Sinothorn	ABDM	รายงานผล : ABDM รับได้รับแต่งตั้งให้ดูแลโครงการ "อช...	['รายงานผล', ':', 'ABDM', 'รับได้รับแต่งตั้งให้ดูแลโครงการ', '"อช...', '']	38	1
76490	2017-09-06 00:00:00	BangkokBusiness	IFEC	เชิญให้คณะกรรมการที่ปรึกษาผู้รับ บอกรายงาน 6/2017 รายงาน...	['เชิญให้', 'คณะกรรมการที่ปรึกษาผู้รับ', 'บอกรายงาน', '6/2017', 'รายงาน...']	36	0
117186	2018-05-11 00:00:00	BangkokBusiness	EV	"นิคม"ผลิตแบตเตอรี่ 7 ปี...จะผลิต แบตเตอรี่ 7 ปี...จะผลิต...	['"นิคม"', 'ผลิตแบตเตอรี่', '7', 'ปี...', 'จะผลิต', 'แบตเตอรี่', '7', 'ปี...', 'จะผลิต...']	36	0
215268	2021-01-05 00:00:00	BangkokBusiness	EA	"EA" รวบรวมเงิน 15.63N ได้ถึงเกณฑ์ 5 ปี...ได้ถึงเกณฑ์...	['"EA"', 'รวบรวมเงิน', '15.63N', 'ได้ถึงเกณฑ์', '5', 'ปี...', 'ได้ถึงเกณฑ์...']	36	0
223038	2021-03-12 00:00:00	BangkokBusiness	WAT	"WAT" 5 ปี...จะผลิต แบตเตอรี่ 7 ปี...จะผลิต...	['"WAT"', '5', 'ปี...', 'จะผลิต', 'แบตเตอรี่', '7', 'ปี...', 'จะผลิต...']	36	1
173352	2019-08-30 16:12:16	Pattia Sinothorn	EA	บริษัท 5 ปี...จะผลิต แบตเตอรี่ 7 ปี...จะผลิต...	['บริษัท', '5', 'ปี...', 'จะผลิต', 'แบตเตอรี่', '7', 'ปี...', 'จะผลิต...']	36	1
199746	2020-07-28 00:00:00	BangkokBusiness	CBS	"CBS" 5 ปี...จะผลิต แบตเตอรี่ 7 ปี...จะผลิต...	['"CBS"', '5', 'ปี...', 'จะผลิต', 'แบตเตอรี่', '7', 'ปี...', 'จะผลิต...']	36	1
233883	2021-06-30 00:00:00	BangkokBusiness	TU	2ND ผู้ถือหุ้นใน 49...จะผลิต แบตเตอรี่ 7 ปี...จะผลิต...	['2ND', 'ผู้ถือหุ้นใน', '49...', 'จะผลิต', 'แบตเตอรี่', '7', 'ปี...', 'จะผลิต...']	36	1

ภาพที่ 2.3 ตัวอย่าง Data Frame หลังจาก Data Preparation

โดยงานวิจัยนี้มีการใช้ Classification Model ที่เหมาะกับ Data set ขนาดใหญ่ ดังนี้ 1.) SGD-classifier 2.) XGBoost Classifier 3.) K-Nearest Neighbors 4.) Naïve Bayes 5.) Neural Network โดยในแต่ละโมเดลจะมีการหา best parameter ของ tuning parameter จากนั้นจึงนำแต่ละโมเดลไปทดสอบประสิทธิภาพ โดยมีการแบ่งชุดข้อมูล 80% ไว้สำหรับฝึกโมเดล และ 20% สำหรับทดสอบโมเดล สรุปผลจากการทดสอบโมเดลพบว่า Neural Network มีประสิทธิภาพโดยรวมและค่าการทำนายที่ดีที่สุดคือ 56.88% และ 61.7%

ภาพที่ 4.20

Performance of all classifiers

Classifier Model	Precision	Recall	F1-score	Accuracy	Overall performance
XGB	56.5	50.0	38.0	59.0	50.88
SGD	53.5	50.5	39.0	59.0	50.50
KNN	55.5	54.0	53.0	58.0	55.13
NB	54.0	53.0	52.5	53.0	53.13
NN	59.3	55.4	51.1	61.7	56.88

ภาพที่ 2.4 ตารางสรุปประสิทธิภาพของโมเดล

โดยงานวิจัยนี้มีข้อเสนอแนะที่น่าสนใจคือ

1. ควรเพิ่มแนวคิดของ Moving Average เนื่องจากหุ้นบางตัวมีช่วงราคาที่เยอะ และความผันผวนสูงหากนำราคาก่อนและหลังมาใช้อาจจะไม่สะท้อนแนวโน้มของมูลค่าตามตลาด โดย Moving Average จะนำราคาย้อนหลังมาเฉลี่ยตามช่วงเวลาที่กำหนด
2. ควรออกแบบโมเดลตามอุตสาหกรรมของหุ้น เนื่องจากธรรมชาติของแต่ละอุตสาหกรรมนั้นมีความแตกต่างกัน

2.2.2 งานวิจัยเรื่อง “Pearson Correlation Coefficient-Based Performance Enhancement of Broad Learning System for Stock Price Prediction” (Li et al., 2022)

Li et al. (2022) นำเสนอ Framework ที่ใช้ Pearson Correlation Coefficient (PCC) ในการคัดเลือก Feature จากชุดข้อมูล 35 Features ซึ่งประกอบด้วยราคาหุ้น Technical Indicators และ Financial Indicators จากนั้นนำ Feature ที่ผ่านการคัดเลือกไป Train ด้วย Broad Learning System (BLS) เพื่อพยากรณ์ราคาปิดของหุ้น 4 ตัวในตลาดหลักทรัพย์เชียงใหม่และเชียงใหม่

ผลการทดลองพบว่าโมเดล PCC-BLS มีประสิทธิภาพดีกว่า 10 วิธีเปรียบเทียบ เช่น SVR, Random Forest, GRU และ Adaboost ข้อจำกัดสำคัญของงานวิจัยนี้คือ PCC ใช้ Threshold ตายตัวซึ่งอาจตัด Feature ที่มี Non-linear Relationship ออกไปโดยไม่ตั้งใจ และไม่มีการใช้ Explainable AI อธิบายว่าทำไม Feature นั้นจึงสำคัญต่อโมเดล ซึ่งเป็นช่องว่างที่โครงการนี้มุ่งเติมเต็ม

2.2.3 งานวิจัยเรื่อง “Explainable Stock Prices Prediction from Financial News Articles using Sentiment Analysis” (Gite et al., 2021)

Gite et al. (2021) เสนอแนวทางการพยากรณ์ราคาหุ้นโดยรวมข้อมูลราคาหุ้น Time-series เข้ากับ Sentiment จากข่าวการเงิน โดยใช้ LSTM เป็นโมเดลหลักและ Explainable AI เพื่ออธิบายผลการทำนาย ข้อมูลที่ใช้ได้แก่ ราคาหุ้นใน National Stock Exchange (NSE) ของอินเดีย และ Headlines ข่าวการเงินกว่า 210,000 รายการ

งานวิจัยนี้เป็นหนึ่งในงานแรกๆ ที่นำ Explainable AI (LIME และ SHAP) มาใช้ร่วมกับ LSTM ในการพยากรณ์ราคาหุ้น อย่างไรก็ตาม

ยังจำกัดอยู่ที่ตลาดหุ้นอินเดียเพียงตลาดเดียว และไม่ได้เปรียบเทียบ SHAP กับวิธีคัดเลือก Feature แบบดั้งเดิมเช่น Pearson Correlation โดยตรง ซึ่งเป็นสิ่งที่โครงการนี้ทำเป็นหลัก

2.2.4 งานวิจัยเรื่อง “Significance of Predictors: Revisiting Stock Return Predictions using Explainable AI” (Annals of Operations Research, 2025)

งานวิจัยนี้ตีพิมพ์ใน Annals of Operations Research (2025) ใช้ SHAP ร่วมกับโมเดล Machine Learning หลายประเภท ได้แก่ Random Forest, Gradient Boosting และ Deep Neural Network เพื่อวิเคราะห์ว่า Feature ใดมีความสำคัญต่อการพยากรณ์ผลตอบแทนหุ้น โดยเน้นที่การเปรียบเทียบ Explainability ระหว่างโมเดลประเภทต่างๆ และการระบุ Feature ที่สอดคล้องกันข้าม Model

งานวิจัยพบว่า SHAP ให้ Insight เกี่ยวกับความสำคัญของ Feature ที่ลึกกว่าวิธีดั้งเดิม โดยเฉพาะในส่วนของ Non-linear Effect ที่ Feature มีต่อผลการทำนาย ข้อจำกัดคือไม่ได้เปรียบเทียบโดยตรงกับ Pearson Correlation และไม่ได้วิเคราะห์ในระดับ Sector ซึ่งโครงการนี้ดำเนินการทั้งสองอย่าง

ผลที่น่าสนใจอีกประการหนึ่งคือ SHAP แสดงให้เห็นว่า Feature บางตัวที่ Pearson Correlation จัดว่าไม่สำคัญกลับมีผลต่อโมเดลในเชิง Non-linear อย่างมีนัยสำคัญ ซึ่งสอดคล้องกับผลการวิจัยของโครงการนี้ที่พบว่า Bond_yield และ Volatility_5d มี Rank Disagreement สูงสุดระหว่าง Correlation และ SHAP

2.3 เปรียบเทียบงานวิจัยและแนวทางของโครงการ

ตารางที่ 2.1 แสดงการเปรียบเทียบงานวิจัยที่เกี่ยวข้องกับแนวทางของโครงการในด้านข้อมูล โมเดล วิธี

คัดเลือก Feature และการใช้ Explainable AI

งานวิจัย	วันที่ตีพิมพ์	ข้อมูลที่ใช้	โมเดล	Feature Selection	Explainable AI	ข้อจำกัด
เรียว (2566)	2566	ข่าวหุ้นไทย + ราคา	TF-IDF + Classical ML	TF-IDF	ไม่มี	ไม่มี XAI, Linear only
Li et al. (2022)	2022	ราคา+Technical+Financial 35 features	Broad Learning System	Pearson Correlation	ไม่มี	Threshold ตายตัว ไม่อธิบายเหตุผล
Gite et al. (2021)	2021	ราคา NSE + ข่าว 210,000 รายการ	LSTM + XAI	Sentiment-based	LIME, SHAP	จำกัดตลาดเดียว ไม่เปรียบเทียบ Corr vs SHAP
Annals (2025)	2025	ข้อมูลหุ้น Cross-sectional	RF, GBM, DNN	ไม่ระบุ	SHAP	ไม่เปรียบเทียบกับ Pearson โดยตรง
โครงการนี้	2568	OHLCV + S&P500 + Bond Yield + VIX 27 features	LSTM+Attention + RF + LR + Ensemble	Pearson Corr vs SHAP (เปรียบเทียบโดยตรง)	SHAP Global+Local+Cross-model+Sector	-

จากตารางที่ 2.1 จะเห็นว่าโครงงานนี้มีจุดเด่นที่แตกต่างจากงานวิจัยก่อนหน้านี้คือ การเปรียบเทียบ Pearson Correlation กับ SHAP โดยตรงในบริบทเดียวกัน ซึ่งไม่มีงานวิจัยใดทำมาก่อนอย่างครบถ้วน นอกจากนี้ยังมีการวิเคราะห์ในระดับ Sector และ Cross-model SHAP Consistency ซึ่งเพิ่มความน่าเชื่อถือของผลการวิจัย

บทที่ 3

วิธีการวิจัย

3.1 ภาพรวมของโครงการ

โครงการนี้ดำเนินการตามกระบวนการวิจัย 5 ขั้นตอนหลัก ได้แก่ (1) การรวบรวมข้อมูล (2) Feature Engineering และการเปรียบเทียบ Correlation กับ SHAP (3) การสร้างและฝึกฝนโมเดล LSTM + Attention Mechanism (4) การทดลอง 5 Experiments และ (5) การวิเคราะห์และสรุปผล

ขั้นที่ 1 การเก็บรวบรวมข้อมูลถึงข้อมูลราคาหุ้นรายวันของ 10 หุ้นจาก 5 Sector ผ่าน yfinance API ครอบคลุมช่วงมกราคม 2563 ถึงเมษายน 2568 (1,318 วันทำการต่อหุ้น) แบ่งชุดข้อมูลเป็น Train/Test อัตราส่วน 80:20 ตามลำดับเวลา

ขั้นที่ 2 Feature Engineering คำนวณ 27 ตัวแปรใน 5 กลุ่ม (Price-based, Volume-based, Trend, Momentum, Market-wide) จากนั้นคัดเลือก Feature ผ่านทั้ง Pearson Correlation (ตัด Feature ที่ $|r| < 0.05$) และ SHAP Values ผ่าน RandomForest Baseline เพื่อเปรียบเทียบความสอดคล้องระหว่างทั้งสองวิธี

ขั้นที่ 3 สร้างโมเดล LSTM+Attention Architecture สามชั้นลำดับ Hidden Dimension = 128 Dropout = 0.2 และ Temporal Attention Layer เทรนด้วย Focal Loss ($\gamma = 2$) เพื่อแก้ปัญหา Class Imbalance และหา Optimal Threshold ด้วยการ Scan บน Validation Set

ขั้นที่ 4 คัดเลือก 5 การทดลองตามลำดับ เริ่มจาก Baseline LSTM เพิ่ม VIX Features วิเคราะห์ SHAP Consistency วิเคราะห์ระดับ Sector จนถึงการเพิ่ม Ensemble Model เพื่อเพิ่มความเสถียรของการพยากรณ์

ขั้นที่ 5 ประเมินผลด้วย 4 ตัวชี้วัด ได้แก่ Accuracy, F1-Score (Macro), ROC-AUC และ Rank Disagreement เพื่อตอบคำถามวิจัยหลักทั้งสองข้อ ได้แก่ ประสิทธิภาพของการพยากรณ์ทิศทางราคาหุ้น และความสอดคล้องระหว่างการจัดลำดับ Feature ด้วย Pearson กับ SHAP

3.2 การรวบรวมข้อมูล (Data Collection)

โครงการรวบรวมข้อมูลจาก 2 แหล่งหลักผ่าน yfinance API ได้แก่ (1) ข้อมูลราคาหุ้นรายวัน (OHLCV) ของ 10 หุ้น ได้แก่ NVDA, TSLA, JNJ, UNH, XOM, CVX, JPM, GS, AMZN, COST ตั้งแต่ มกราคม 2020 ถึง เมษายน 2025 รวม 1,300+ วันทำการ และ (2) ข้อมูล Market-wide ได้แก่ S&P 500 Index (^GSPC), Bond Yield 10 ปี (^TNX) และ VIX Index (^VIX) ดึงผ่าน yfinance เช่นกัน ไม่ได้ใช้ FRED API

ข้อมูลถูกแบ่งเป็น Train 80% และ Test 20% ตามลำดับเวลา (Time-ordered split) ไม่สุ่ม เพื่อป้องกัน Data Leakage จากอนาคต

3.3 Feature Engineering

สร้าง Technical Indicators จากข้อมูลราคาและปริมาณการซื้อขาย รวม 27 Features แบ่งเป็น 5 กลุ่ม ดังนี้

กลุ่มที่ 1 — Price-based (6 Features): Return_1d, Return_3d, Return_5d, Return_10d, Volatility_5d, Volatility_20d วัดการเปลี่ยนแปลงและความผันผวนของราคา

กลุ่มที่ 2 — Trend (6 Features): MA5, MA20, MA50, EMA12, EMA26, Price_MA20_dist วัดทิศทางแนวโน้มของราคา

กลุ่มที่ 3 — Momentum (6 Features): RSI, MACD, MACD_signal, MACD_diff, Stoch_k, Stoch_d วัดความแรงและทิศทางของการเปลี่ยนแปลง

กลุ่มที่ 4 — Volume (4 Features): Volume_change, OBV, Volume_MA20, Volume_MA_ratio วิเคราะห์ปริมาณการซื้อขาย

กลุ่มที่ 5 — Market-wide (5 Features): SP500_return, SP500_MA20, SP500_vol, Relative_return, Bond_yield สะท้อนสถานะตลาดโดยรวม

Target Variable คือทิศทางราคา 3 วันข้างหน้า (3-day Forward Return) แบบ Binary Classification: ค่า 1 หมายถึงราคาขึ้น (Forward Return > 0) และค่า 0 หมายถึงราคาลง ไม่ได้ใช้ Next-day Prediction หรือ 5-class Classification

ข้อมูลทุก Feature ผ่านการ Normalize ด้วย StandardScaler และสร้างเป็น Sequence ขนาด 60 วันทำการ (Trading Days) (Sliding Window, Sequence Length = 60) ซึ่งเทียบเท่ากับประมาณ 3 เดือนปฏิทิน เพื่อเป็น Input ให้โมเดล การเลือก Window Size ขนาดนี้ สอดคล้องกับรอบการรับรู้ข้อมูลทางเศรษฐกิจและรอบการประกาศงบการเงินรายไตรมาส (Quarterly Earnings Cycle) ของบริษัทในตลาดหุ้นสหรัฐฯ ทำให้โมเดลสามารถเรียนรู้รูปแบบราคา ที่ครอบคลุมหนึ่งรอบรายงานผลประกอบการได้

3.4 โมเดลที่ใช้ในโครงงาน (Model Architecture)

โมเดลหลักที่ใช้คือ LSTM + Attention Mechanism ประกอบด้วย LSTM 3 ชั้น (hidden_size=128, dropout=0.2) และ Attention Layer ที่ช่วยให้โมเดลเลือกได้ว่า Timestep ใดสำคัญที่สุด ใช้ Focal Loss (gamma=2) ร่วมกับ Class Weight เพื่อแก้ Class Imbalance และ Early Stopping patience=20 epochs โดย Monitor F1-Score แทน Accuracy โดย Focal Loss มีสูตรดังนี้

$$FL(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t)$$

โดยที่ p_t คือความน่าจะเป็นที่โมเดลทำนายสำหรับ Class ที่ถูกต้อง, α_t คือ Class Weight ที่ปรับสมดุลความไม่สมดุลของ Class และ γ คือ Focusing Parameter (ใช้ค่า 2) ที่ลดน้ำหนักของตัวอย่างที่จำแนกสูง ทำให้โมเดลเน้นเรียนรู้จากตัวอย่างที่ยากแทน (Lin et al., 2017) ผลข้างเคียงของ Focal Loss คือทำให้ Probability Distribution ของคลาสสับวามีแนวโน้มต่ำกว่า 0.50 ซึ่งเป็นเหตุผลที่ Optimal Threshold ของหุ้นส่วนใหญ่ลดลงเหลือ 0.30 คือการปรับ Threshold ให้สอดคล้องกับ Probability Distribution จริงแทนที่จะใช้ค่า Default 0.50

Baseline Models ที่ใช้เปรียบเทียบ ได้แก่ Random Forest (n_estimators=200) และ Logistic Regression (max_iter=1000) ทั้งสองโมเดลใช้ Feature เดียวกันกับ LSTM เพื่อให้การเปรียบเทียบ SHAP Importance ข้าม Model มีความยุติธรรม

Ensemble Model สร้างโดยใช้ Soft Voting คำนวณค่าเฉลี่ยของ Probability จากทั้ง 3 Models แล้วเปรียบเทียบกับ Optimal Threshold ที่ Scan ในช่วง 0.30-0.70 เพื่อ Maximize F1-Score ของแต่ละหุ้น

3.5 การออกแบบการทดลอง (Experiment Design)

โครงงานนี้ออกแบบการทดลองไว้ 5 Experiments เพื่อตอบวัตถุประสงค์ทั้ง 5 ข้อ

Experiment 1 — Pearson Correlation vs SHAP: คำนวณ Absolute Pearson Correlation ระหว่าง Feature แต่ละตัวกับ Target และคำนวณ SHAP Values ด้วย KernelExplainer จากนั้นเปรียบเทียบ Feature Ranking ของทั้งสองวิธีโดยวัด Rank Disagreement ($|\text{Corr_rank} - \text{SHAP_rank}|$) เฉลี่ยข้าม 10 หุ่น จากนั้นนำ Top-10 features ของ SHAP และ Pearson Correlation มาเทรนโมเดล LSTM เพื่อเปรียบเทียบประสิทธิภาพ

Experiment 2 — Cross-model SHAP Consistency: วิเคราะห์ SHAP Feature Importance จาก 3 Models (LSTM, Random Forest, Logistic Regression) และตรวจสอบว่า Feature ใดปรากฏใน Top-5 อย่างสอดคล้องกันข้าม Model เพื่อยืนยัน Feature ที่สำคัญในเชิง Model-agnostic

Experiment 3 — LSTM + VIX Sentiment: เพิ่ม VIX Features 5 ตัว (VIX, VIX_change, VIX_MA5, VIX_MA20, Fear_level) เข้าใน Feature Set แล้ว Train LSTM ใหม่ เปรียบเทียบ Accuracy และ F1-Score กับ Baseline ที่ไม่มี VIX

Experiment 4 — Ensemble Model: รวมผลทำนายจาก LSTM, Random Forest และ Logistic Regression ด้วย Soft Voting และหา Optimal Threshold ต่อหุ่นเพื่อ Maximize F1-Score

Experiment 5 — Sector-level SHAP Analysis: คำนวณ SHAP Feature Importance เฉลี่ยต่อ Sector แล้ววิเคราะห์ว่าหุ่นใน Sector เดียวกันมี Feature ที่สำคัญสอดคล้องกันหรือไม่

3.6 เกณฑ์การวัดผล (Evaluation Metrics)

โครงงานใช้ตัวชี้วัด 4 ประเภท ได้แก่

- (1) Accuracy — สัดส่วนการทำนายถูกต้องโดยรวม
- (2) F1-Score — ค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall เลือกใช้เป็น Primary Metric เพราะข้อมูลมี Class Imbalance
- (3) ROC-AUC — วัดความสามารถในการจัดอันดับ Probability ของการขึ้น/ลง

(4) Rank Disagreement — $|\text{Corr_rank} - \text{SHAP_rank}|$ เฉลี่ยข้าม 10 หุ้น
วัดความแตกต่างในการจัดอันดับ Feature ระหว่าง Pearson Correlation และ SHAP

สมการสำหรับตัวชี้วัดหลักที่ใช้ในโครงงานนี้มีดังนี้

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{F1-Score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

โดยที่ TP (True Positive) คือจำนวนตัวอย่างที่โมเดลทำนายถูกว่าราคาขึ้นและราคาขึ้นจริง, FP (False Positive) คือโมเดลทำนายขึ้นแต่ราคาจริง, และ FN (False Negative) คือโมเดลทำนายลงแต่ราคาขึ้นจริง โครงงานนี้ใช้ F1-Score แบบ Macro Average ซึ่งคำนวณค่าเฉลี่ยของ F1 ทั้งสอง Class (ขึ้น/ลง) โดยไม่ถ่วงน้ำหนักตามสัดส่วน เพื่อให้การประเมินผลมีความเป็นธรรมในชุดข้อมูลที่ไม่สมดุล

บทที่ 4

ผลการทดลองและการวิเคราะห์

4.1 ผลการรวบรวมข้อมูล

ได้ทำการรวบรวมข้อมูลราคาของหุ้น 10 ตัวในภาคอุตสาหกรรม 5 ประเภท รวมถึงข้อมูลดัชนี S&P 500 และข้อมูลพันธบัตรรัฐบาลอเมริกา (Bond Yield) จากไลบรารีใน python คือ yfinance โดยข้อมูลที่น่าเข้าจะมีช่วงเวลาตั้งแต่วันที่ 1 มกราคม ค.ศ. 2020 จนถึง 25 เมษายน ค.ศ. 2025 จำนวนข้อมูลที่รวบรวมเป็นดังภาพ

```
[*****100%*****] 10 of 10 completed
NVDA (Technology): 1335 rows
TSLA (Technology): 1335 rows
JNJ (Healthcare): 1335 rows
UNH (Healthcare): 1335 rows
XOM (Energy): 1335 rows
CVX (Energy): 1335 rows
JPM (Finance): 1335 rows
GS (Finance): 1335 rows
AMZN (Consumer): 1335 rows
COST (Consumer): 1335 rows
[*****100%*****] 1 of 1 completed
[*****100%*****] 1 of 1 completed

S&P500: 1315 rows | Bond Yield: 1335 rows
```

ภาพที่ 4.1.1 ผลการรวบรวมข้อมูลจาก yfinance

	Open	High	Low	Close	Volume
Date					
2020-01-02	5.941885	5.970754	5.891364	5.970754	237536000
2020-01-03	5.851045	5.918988	5.826157	5.875185	205384000
2020-01-06	5.781858	5.905050	5.755726	5.899824	262636000
2020-01-07	5.928197	6.017045	5.883151	5.971252	314856000
2020-01-08	5.967022	6.023765	5.926953	5.982452	277108000

ภาพที่ 4.1.2 ตัวอย่างข้อมูลราคาหุ้น NVIDIA (NVDA) ที่รวบรวมจาก yfinance

Price	Close	High	Low	Open	Volume
Ticker	^GSPC	^GSPC	^GSPC	^GSPC	^GSPC
Date					
2020-01-02	3257.850098	3258.139893	3235.530029	3244.669922	3459930000
2020-01-03	3234.850098	3246.149902	3222.340088	3226.360107	3484700000
2020-01-06	3246.280029	3246.840088	3214.639893	3217.550049	3702460000
2020-01-07	3237.179932	3244.909912	3232.429932	3241.860107	3435910000
2020-01-08	3253.050049	3267.070068	3236.669922	3238.590088	3726840000

ภาพที่ 4.1.3 ตัวอย่างข้อมูลดัชนี S&P 500 (^GSPC) ที่รวบรวมจาก yfinance

Price	Close	High	Low	Open	Volume
Ticker	^TNX	^TNX	^TNX	^TNX	^TNX
Date					
2020-01-02	1.882	1.903	1.851	1.903	0
2020-01-03	1.788	1.840	1.786	1.828	0
2020-01-06	1.811	1.816	1.766	1.785	0
2020-01-07	1.827	1.828	1.797	1.797	0
2020-01-08	1.874	1.876	1.802	1.823	0

ภาพที่ 4.1.4 ตัวอย่างข้อมูล US 10-Year Treasury Yield (^TNX) ที่รวบรวมจาก yfinance

Price	Close	High	Low	Open	Volume
Ticker	Δ VIX	Δ VIX	Δ VIX	Δ VIX	Δ VIX
Date					
2020-01-02	12.47	13.720000	12.42	13.46	0
2020-01-03	14.02	16.200001	13.13	15.01	0
2020-01-06	13.85	16.389999	13.54	15.45	0
2020-01-07	13.79	14.460000	13.39	13.84	0
2020-01-08	13.45	15.240000	12.83	15.16	0

ภาพที่ 4.1.5 ตัวอย่างข้อมูล CBOE Volatility Index (Δ VIX) ที่รวบรวมจาก yfinance

4.2 ผลการทำ Feature Engineering

หลังจากรวบรวมข้อมูล ขั้นตอนต่อมาคือการทำ Feature Engineering โดยใช้ข้อมูลราคาของหุ้นบวกกับข้อมูล S&P500 และ Bond Yield และทำการ drop rows วันที่ข้อมูลไม่ตรงกันจากนั้นทำการตรวจสอบว่าคลาสของข้อมูลว่า Balance หรือไม่ ผลลัพธ์เป็นดังภาพที่

Ticker	Sector	Rows	UP%	DOWN%	Balance
NVDA	Technology	1283	57.1	42.9	✓ OK
TSLA	Technology	1283	52.1	47.9	✓ OK
JNJ	Healthcare	1283	51.4	48.6	✓ OK
UNH	Healthcare	1283	54.9	45.1	✓ OK
XOM	Energy	1283	54.8	45.2	✓ OK
CVX	Energy	1283	54.9	45.1	✓ OK
JPM	Finance	1283	57.4	42.6	✓ OK
GS	Finance	1283	54.5	45.5	✓ OK
AMZN	Consumer	1283	51.4	48.6	✓ OK
COST	Consumer	1283	59.9	40.1	✓ OK

ภาพที่ 4.2.1 ผลลัพธ์จากการทำ Feature Engineering

	Return_1d	Return_3d	Return_5d	Return_10d	Volatility_5d
Date					
2020-03-13	0.113402	-0.077524	-0.094723	-0.108231	0.099731
2020-03-16	-0.184521	-0.203149	-0.199805	-0.289513	0.124675
2020-03-17	0.106263	0.004438	-0.167803	-0.182858	0.134355
2020-03-18	-0.066507	-0.157864	-0.177101	-0.287125	0.134972
2020-03-19	0.050044	0.084369	-0.015441	-0.220718	0.127532

ภาพที่ 4.2.2 Feature ด้าน Return และ Volatility ที่ได้จาก Feature Engineering

	Volatility_20d	MA5	MA20	MA50	EMA12	EMA26	Price_MA20_dist	RSI	MACD	MACD_signal
Date										
2020-03-13	0.063552	6.027069	6.729118	6.404515	6.332031	6.482803	-0.108726	44.435976	-0.139939	0.004274
2020-03-16	0.072776	5.782827	6.613052	6.382916	6.110262	6.362503	-0.260429	35.289266	-0.244535	-0.045488
2020-03-17	0.077388	5.564632	6.514535	6.373623	6.002594	6.290674	-0.169467	41.390686	-0.282238	-0.092838
2020-03-18	0.076252	5.347234	6.375465	6.356641	5.856127	6.197243	-0.207792	38.671875	-0.337265	-0.141723
2020-03-19	0.077793	5.330600	6.256500	6.343285	5.771091	6.129982	-0.152328	41.574953	-0.356372	-0.184653

ภาพที่ 4.2.3 Feature ด้าน Moving Average, RSI และ MACD ที่ได้จาก Feature Engineering

	MACD_diff	Stoch_k	Stoch_d	Volume_change	OBV
Date					
2020-03-13	-0.144214	36.242535	16.461306	-0.222529	1771232000
2020-03-16	-0.199047	2.640549	13.207087	0.145134	1044260000
2020-03-17	-0.189400	27.979541	22.287542	0.146718	1877892000
2020-03-18	-0.195542	21.245549	17.288546	0.048746	1003624000
2020-03-19	-0.171719	30.985514	26.736868	-0.124397	1769136000

ภาพที่ 4.2.4 Feature ด้าน Stochastic Oscillator, Volume และ OBV ที่ได้จาก Feature Engineering

	Volume_MA20	Volume_MA_ratio	SP500_return	SP500_MA20	SP500_vol	Relative_return	Bond_yield	Forward_return	Target
Date									
2020-03-13	748864800.0	0.847731	0.092871	3051.645483	0.043920	0.020531	0.951	-0.157864	0
2020-03-16	733117200.0	0.991618	-0.119841	3001.943982	0.050181	-0.064680	0.728	0.084369	1
2020-03-17	743790600.0	1.120789	0.059955	2959.888977	0.052940	0.046308	0.997	-0.053022	0
2020-03-18	752787400.0	1.161374	-0.051831	2910.486487	0.053458	-0.014676	1.266	0.048664	1
2020-03-19	750560400.0	1.019921	0.004708	2862.294482	0.053591	0.045337	1.119	0.170024	1

ภาพที่ 4.2.5 Feature ด้าน Market-wide (S&P500, Bond Yield) และ Target ที่ได้จาก Feature Engineering

4.3 ผลการเทรนโมเดล LSTM ทุกหุ้น+หา Optimal Threshold

เทรนโมเดลสำหรับหุ้นทั้ง 10 ตัวโดยมีการหาค่า Threshold ที่ให้ F1-Score สูงที่สุดสำหรับโมเดลแต่ละตัวแทนที่ค่า default = 0.5 ผลลัพธ์การเทรนเป็นดังภาพ

```
Using device: cuda
=== Training NVDA ===
NVDA | Epoch 30 | Loss: 0.1628 | Acc: 0.5429 | F1: 0.6973
NVDA | Early stopping at epoch 47 | Best F1: 0.7014
NVDA | Best F1: 0.7014

NVDA | Optimal threshold: 0.45 | F1@threshold: 0.6912

=== Training TSLA ===
TSLA | Early stopping at epoch 27 | Best F1: 0.4080
TSLA | Best F1: 0.4080

TSLA | Optimal threshold: 0.30 | F1@threshold: 0.6685

=== Training JNJ ===
JNJ | Early stopping at epoch 24 | Best F1: 0.6452
JNJ | Best F1: 0.6452

JNJ | Optimal threshold: 0.30 | F1@threshold: 0.6933

=== Training UNH ===
UNH | Early stopping at epoch 24 | Best F1: 0.4550
UNH | Best F1: 0.4550

UNH | Optimal threshold: 0.30 | F1@threshold: 0.7500
```

ภาพที่ 4.3.1 ผลลัพธ์หลังจากเทรนโมเดล LSTM ของหุ้น 10 ตัว (1)

```
=== Training XOM ===
XOM | Early stopping at epoch 22 | Best F1: 0.6968
XOM | Best F1: 0.6968

XOM | Optimal threshold: 0.30 | F1@threshold: 0.6968

=== Training CVX ===
CVX | Epoch 30 | Loss: 0.1681 | Acc: 0.5102 | F1: 0.5745
CVX | Epoch 60 | Loss: 0.1568 | Acc: 0.5102 | F1: 0.6129
CVX | Early stopping at epoch 61 | Best F1: 0.6986
CVX | Best F1: 0.6986

CVX | Optimal threshold: 0.30 | F1@threshold: 0.6898

=== Training JPM ===
JPM | Epoch 30 | Loss: 0.1663 | Acc: 0.5388 | F1: 0.5022
JPM | Early stopping at epoch 46 | Best F1: 0.6746
JPM | Best F1: 0.6746

JPM | Optimal threshold: 0.30 | F1@threshold: 0.7474

=== Training GS ===
GS | Early stopping at epoch 21 | Best F1: 0.0000
GS | Best F1: 0.0000

GS | Optimal threshold: 0.30 | F1@threshold: 0.7240
```

ภาพที่ 4.3.2 ผลลัพธ์หลังจากเทรนโมเดล LSTM ของหุ้น 10 ตัว (2)

```

=== Training AMZN ===
AMZN | Early stopping at epoch 30 | Best F1: 0.6630
AMZN | Best F1: 0.6630

AMZN | Optimal threshold: 0.30 | F1@threshold: 0.6612

=== Training COST ===
COST | Early stopping at epoch 21 | Best F1: 0.0000
COST | Best F1: 0.0000

COST | Optimal threshold: 0.30 | F1@threshold: 0.7500


=== Optimal Thresholds ===
NVDA: 0.45
TSLA: 0.30
JNJ: 0.30
UNH: 0.30
XOM: 0.30
CVX: 0.30
JPM: 0.30
GS: 0.30
AMZN: 0.30
COST: 0.30

```


ภาพที่ 4.3.3 ผลลัพธ์หลังจากเทรนโมเดล LSTM ของหุ้น 10 ตัว (3)

4.4 ผลการเปรียบเทียบ Pearson Correlation กับ SHAP


Correlation และ SHAP ให้ Feature Ranking ต่างกันเฉลี่ย 5-12 อันดับต่อ Feature โดย Volatility_5d มีความแตกต่างสูงสุด เนื่องจาก Correlation วัดได้แค่ Linear Relationship Bond_yield ติด SHAP Top-5 ใน 8/10 หุ้น แต่ Correlation จัดอันดับต่ำ พิสูจน์ว่า SHAP จับ Non-linear Macro-economic Effect ได้ที่ Correlation จับไม่ได้




ภาพที่ 4.4.1 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (1)




ภาพที่ 4.4.2 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (2)




ภาพที่ 4.4.3 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (3)




ภาพที่ 4.4.4 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (4)



ภาพที่ 4.4.5 กราฟเปรียบเทียบ feature importance ของ SHAP และ Pearson Correlation (5)



ภาพที่ 4.4.6 กราฟแสดง feature rank disagreement ระหว่าง SHAP และ Pearson Correlation heatmap (กราฟด้านซ้าย) กราฟแท่ง (กราฟด้านขวา)



ภาพที่ 4.4.7 ตัวอย่าง Local SHAP Explanation ของหุ้น NVDA 5 วัน

=== OBV Rank across models ===				
Ticker	Sector	LSTM	RF	LR
NVDA	Technology	23	4	1
TSLA	Technology	12	3	8
JNJ	Healthcare	12	24	1
UNH	Healthcare	13	7	22
XOM	Energy	3	7	3
CVX	Energy	18	4	4
JPM	Finance	6	8	21
GS	Finance	20	23	11
AMZN	Consumer	9	16	10
COST	Consumer	21	6	1


ภาพที่ 4.4.8 Feature ranking ของ OBV ทั้งสามโมเดล

=== Bond_yield SHAP Rank across all stocks ===			
Ticker	Sector	Bond_yield Rank	SHAP Value
NVDA	Technology	6	0.0197
TSLA	Technology	1	0.0219
JNJ	Healthcare	22	0.0016
UNH	Healthcare	6	0.0158
XOM	Energy	9	0.0078
CVX	Energy	11	0.0064
JPM	Finance	1	0.0515
GS	Finance	16	0.0018
AMZN	Consumer	1	0.0710
COST	Consumer	4	0.0072

ภาพที่ 4.4.9 Feature ranking ของ bond yield

4.5 ผลทดสอบ Feature Quality ของ SHAP และ Pearson Correlation ด้วย F1-Score


หลังจากทำ feature ranking ระหว่าง SHAP และ Pearson Correlation นำเอา Top 10 features มาเทรนโมเดล LSTM ผลที่ได้คือ F1-Score ของ SHAP ของหุ้น 6 จาก 10 ตัวมีค่ามากกว่า Pearson Correlation




ภาพที่ 4.5.1 กราฟแสดง accuracy ของโมเดล LSTM ระหว่าง SHAP Top-10 vs Pearson Correlation Top-10

4.6 ผลการวิเคราะห์ Cross-model SHAP Consistency


ตรวจสอบความสอดคล้องของ SHAP Feature Importance ข้าม 3 Models ได้แก่ LSTM, Random Forest (n=200) และ Logistic Regression ผลการทดลองพบว่า OBV (On-Balance Volume) และ Bond_yield ปรากฏใน Top-5 อย่าง Consistent ข้ามทั้ง 3 Models ยืนยันว่า Feature เหล่านี้มีความสำคัญจริงในเชิง Model-agnostic ไม่ใช่ Artifact ของ Model ใด Model หนึ่ง




ภาพที่ 4.6.1 กราฟแสดง SHAP feature importance ของ 3 โมเดล (1)




ภาพที่ 4.6.2 กราฟแสดง SHAP feature importance ของ 3 โมเดล (2)



ภาพที่ 4.6.3 กราฟแสดง SHAP feature importance ของ 3 โมเดล (3)



ภาพที่ 4.6.4 กราฟแสดง SHAP feature importance ของ 3 โมเดล (4)



ภาพที่ 4.6.5 กราฟแสดง SHAP feature importance ของ 3 โมเดล (5)

4.7 ผลการเพิ่ม VIX Sentiment Features


JPM และ COST ตกหนักที่สุด ($-0.2+$) แม้ Fear_level ของ JPM จะมี SHAP สูงพอสมควร (0.0342) แต่ Accuracy กลับตกลงมาก สาเหตุที่เป็นไปได้คือ VIX features รบกวน pattern เดิมที่โมเดลเรียนรู้ได้ดีอยู่แล้ว ทำให้ train ลำบากขึ้นใน 150 epochs เท่าเดิม หรืออาจเกิด overfitting บน training set

UNH ตกหนักรองลงมา (-0.094) สอดคล้องว่า Healthcare เป็น Defensive sector ที่ราคาไม่ได้ตอบสนองต่อ VIX แบบเดียวกับหุ้นทั่วไป การเพิ่ม VIX จึงเป็น noise มากกว่า signal

AMZN มี Fear_level SHAP สูงที่สุด (0.0672) แต่ Accuracy ดีขึ้นเพียงเล็กน้อย ($+0.008$) แสดงว่าโมเดลเรียนรู้ใช้ Fear_level แต่ยังไม่แปลงเป็น prediction ที่ถูกต้องได้มากนัก

ตารางที่ 4.2 ตารางแสดง accuracy ของโมเดลหลังจากเพิ่ม VIX features

หุ้น	Sector	Without VIX	With VIX	เปลี่ยนแปลง
NVDA	Technology	0.5551	0.5510	-0.0041
TSLA	Technology	0.5020	0.5388	+0.0367
JNJ	Healthcare	0.5306	0.5347	+0.0041
UNH	Healthcare	0.6000	0.4122	-0.1878
XOM	Energy	0.5347	0.5429	+0.0082
CVX	Energy	0.5265	0.4816	-0.0449
JPM	Finance	0.6000	0.5020	-0.0980
GS	Finance	0.5673	0.4857	-0.0816
AMZN	Consumer	0.4939	0.4939	+0.0000
COST	Consumer	0.6000	0.5510	-0.0490



ภาพที่ 4.7.1 กราฟแท่งแสดง accuracy ของโมเดล (กราฟด้านซ้าย) heatmap แสดง SHAP importance ของ VIX features (กราฟด้านขวา)

Fear_level คือ VIX Feature ที่โมเดลพึ่งพามากที่สุด เกือบทุกหุ้น โดยหุ้นที่ Fear_level มี SHAP สูงสุด:

AMZN — 0.0672 (เข้มที่สุดในทั้งหมด)

TSLA — 0.0502

JPM — 0.0342

COST — 0.0226


NVDA — 0.0246

ขณะที่ CVX, GS, UNH มี SHAP ของ VIX ทุกตัวต่ำมาก (<0.003) แสดงว่าโมเดลแทบไม่ได้ใช้ VIX ในการตัดสินใจเลย

4.8 ผลการใช้ Ensemble Model

สร้าง Ensemble Model โดยใช้ Soft Voting ร่วมกับ Optimal Threshold (0.30-0.70) สำหรับแต่ละหุ้น ผลการทดลองพบว่า Ensemble ให้ประสิทธิภาพดีกว่าโมเดลรายตัวใน 7 จาก 10 หุ้น โดย F1-Score ที่ดีที่สุด ได้แก่ JPM 0.754, UNH 0.750 และ COST 0.750 ค่าเฉลี่ย F1 ข้ามทุกหุ้นอยู่ที่ประมาณ 0.71 และที่น่าสังเกตคือ Ensemble (เหลือง) ชนะหรือเท่ากับโมเดลที่ดี


ที่สุดในเกือบทุกหุ้น ทั้ง Accuracy และ F1 Score และที่สำคัญกว่าคือ ไม่มีหุ้นไหนเลยที่ Ensemble แพ้ทุกโมเดลพร้อมกัน ทั้งนี้ การที่ค่า Optimal Threshold ของหุ้นส่วนใหญ่ลดลงมาอยู่ที่ 0.30 (จากค่าเริ่มต้น 0.50) เกิดจากการใช้ Focal Loss ($\gamma=2$) ในการเทรนโมเดล ซึ่งส่งผลต่อการกระจายตัวของค่าความน่าจะเป็น (Probability Distribution) ของคลาสบวกและคลาสลบ ทำให้โมเดลมีแนวโน้มให้ค่าความน่าจะเป็นต่ำกว่า 0.50 สำหรับตัวอย่างส่วนใหญ่ การปรับ Threshold ต่ำลงจึงช่วยเพิ่มประสิทธิภาพในการทำนาย (Maximize F1-Score) ได้ดียิ่งขึ้น



ภาพที่ 4.8.1 เปรียบเทียบ Ensemble Model กับ โมเดลอื่นๆ

4.9 ผลการวิเคราะห์ตาม Sector (Sector-level SHAP Analysis)

วิเคราะห์ SHAP Feature Importance ในระดับ Sector เพื่อทำความเข้าใจว่า Feature ไหนมีบทบาทสำคัญในแต่ละภาคอุตสาหกรรม ผลการทดลองพบว่า: ภาคการเงิน (JPM, GS): Bond_yield เป็น SHAP Feature อันดับ 1 ของทั้งสองหุ้น; ภาคพลังงาน (XOM, CVX): SP500_MA20 เป็น SHAP Feature สูงสุดสำหรับทั้งคู่ (ความสอดคล้องสูง); ภาคเทคโนโลยี (NVDA, TSLA): Bond_yield และ Volatility มีความสำคัญสูง; ภาคการแพทย์ (JNJ, UNH): ลักษณะ Feature สำคัญมีความเฉพาะหุ้นสูง ไม่สัมพันธ์กับตลาดมากนัก; ภาคผู้บริโภคร (AMZN, COST): Bond_yield ส่งผลต่ออำนาจซื้อของผู้บริโภค




ภาพที่ 4.9.1 กราฟแสดง SHAP importance ของ feature ตาม sector

4.10 สรุปผลการทดลองทั้งหมด

Ticker	Sector	Thresh	LSTM Acc	LSTM F1	VIX Acc	VIX F1	Ens Acc	Ens F1	Best
NVDA	Technology	0.45	0.5551	0.6912	0.5347	0.6667	0.4653	0.3850	LSTM
TSLA	Technology	0.30	0.5020	0.6685	0.5020	0.6685	0.5061	0.6703	Ensemble
JNJ	Healthcare	0.30	0.5306	0.6933	0.5306	0.6933	0.5306	0.6933	LSTM
UNH	Healthcare	0.30	0.6000	0.7500	0.5918	0.7238	0.6000	0.7500	LSTM
XOM	Energy	0.30	0.5347	0.6968	0.5347	0.6968	0.5347	0.6968	LSTM
CVX	Energy	0.30	0.5265	0.6898	0.5265	0.6898	0.5265	0.6898	LSTM
JPM	Finance	0.30	0.6000	0.7474	0.6082	0.7563	0.6082	0.7563	LSTM+VIX
GS	Finance	0.30	0.5673	0.7240	0.5673	0.7240	0.5673	0.7240	LSTM
AMZN	Consumer	0.30	0.4939	0.6612	0.4939	0.6612	0.4939	0.6612	LSTM
COST	Consumer	0.30	0.6000	0.7500	0.5469	0.6891	0.6000	0.7500	LSTM

ภาพที่ 4.10.1 สรุปผล F1-Score ของแต่ละหุ้นทั้ง 3 โมเดล พร้อมระบุ Best Model

ค่าเฉลี่ย F1 ทั้งหมดอยู่ที่ประมาณ 0.71 โดย Ensemble Model ให้ผลดีกว่า Individual models ใน 7/10 หุ้น Finance sector (JPM) ให้ F1 สูงสุดที่ 0.754



ภาพที่ 4.10.2 สรุปผลการทดลองทั้งหมด (Accuracy, F1-Score ของแต่ละ Model และหุ้น)

บทที่ 5

สรุป

5.1 สรุปผลการวิจัย

โครงการนี้เปรียบเทียบ Pearson Correlation และ SHAP สำหรับการคัดเลือก Feature ในการพยากรณ์ทิศทางราคาหุ้นด้วย LSTM + Attention Mechanism บนข้อมูล 10 หุ้น 5 Sectors ช่วงปี 2020-2025 ผลสรุปได้ดังนี้:

(1) SHAP จับ Non-linear Effect ได้ที่ Correlation จับไม่ได้ โดยเฉพาะ Bond_yield และ Volatility_5d

(2) Bond_yield เป็น Feature ที่สำคัญที่สุดข้าม Sector โดย SHAP แต่ Correlation ไม่สามารถตรวจจับได้

(3) Finance sector (JPM, GS) sensitive กับ Bond_yield มากที่สุด สอดคล้องกับ Financial Theory

(4) Ensemble Model ช่วยเพิ่ม F1 ใน 7/10 หุ้นเฉลี่ย F1 ทั้งหมด ~ 0.71

(5) SHAP มีคุณค่าไม่ใช่แค่ Feature Selection แต่ยังอธิบายการทำนายรายวัน (Local Explanation) ได้

(6) VIX Sentiment Features มีประโยชน์สูงสุดในหุ้นกลุ่ม Technology/Consumer (TSLA +3.7%, AMZN SHAP 0.0672) แต่เป็น Noise สำหรับหุ้นกลุ่ม Healthcare/Finance (UNH - 18.8%, JPM - 9.8%) เนื่องจากราคาหุ้นกลุ่มนี้ใช้ Sector-specific Factors ที่ไม่สัมพันธ์กับความกลัวตลาดโดยรวม แนะนำให้เปิด-ปิด VIX Features ตาม Sector: เปิดสำหรับ Tech/Consumer/Energy ปิดสำหรับ Healthcare/Finance

5.2 ข้อจำกัดของโครงการ

ข้อจำกัดของโครงการนี้ประกอบด้วย: (1) ข้อมูล Fundamental (P/E, EPS) เป็น quarterly จึงไม่ได้นำมา train เพราะ constant fill-forward เพิ่ม noise (2) Threshold = 0.30 ทุกหุ้น อาจมาจาก Focal Loss ทำให้ probability distribution เปลี่ยนไป (3) ข้อมูลข่าว (News Sentiment) ยังไม่ได้รวม

5.3 แนวทางในอนาคต (Future Work)

แนวทางการพัฒนาต่อยอดในอนาคต ได้แก่: (1) FinBERT Sentiment จาก Financial News Headlines เพื่อเปลี่ยนเป็น Multimodal Learning ที่แท้จริง (2) Fundamental Data (P/E, EPS, Profit Margin) แบบ Time-series (3) Transformer/BERT Architecture แทน LSTM (4) Backtesting กลยุทธ์การลงทุนด้วย Signal จาก SHAP

รายการอ้างอิง

- เรียว ศักดิ์ธนะเศรษฐ์. (2566). การคาดการณ์ทิศทางของหุ้นไทยโดยใช้ NLP (Sentiment Analysis) วิเคราะห์จากหัวข้อข่าวของหุ้น. โครงการพิเศษ สาขาวิชาวิทยาการคอมพิวเตอร์, คณะวิทยาศาสตร์และเทคโนโลยี, มหาวิทยาลัยธรรมศาสตร์.
- Li, G., Zhang, A., Zhang, Q., Wu, D., & Zhan, C. (2022). Pearson Correlation Coefficient-Based Performance Enhancement of Broad Learning System for Stock Price Prediction. *IEEE Transactions on Circuits and Systems II: Express Briefs*, 69(5), 2413–2417. <https://doi.org/10.1109/TCSII.2022.3160266>
- Gite, S., Khatavkar, H., Kotecha, K., Srivastava, S., Maheshwari, P., & Pandey, N. (2021). Explainable Stock Prices Prediction from Financial News Articles Using Sentiment Analysis. *PeerJ Computer Science*, 7, e340. <https://doi.org/10.7717/peerj-cs.340>
- Goswami, B., & Uddin, A. (2025). Significance of Predictors: Revisiting Stock Return Predictions Using Explainable AI. *Annals of Operations Research*, 357, 223–257. <https://doi.org/10.1007/s10479-025-06717-2>
- Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774. https://proceedings.neurips.cc/paper_files/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Whaley, R. E. (2000). The investor fear gauge. *Journal of Portfolio Management*, 26(3), 12–17. <https://doi.org/10.3905/jpm.2000.319728>
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *Proceedings of the IEEE International Conference on*

Computer Vision (ICCV), Venice, Italy, 2999–3007.

<https://doi.org/10.1109/ICCV.2017.324>

Hu, Z., Liu, W., Bian, J., Liu, X., & Liu, T.-Y. (2018). Listening to Chaotic Whispers: A Deep Learning Framework for News-oriented Stock Trend Prediction. Proceedings of the 11th ACM International Conference on Web Search and Data Mining, 261–269. <https://doi.org/10.1145/3159652.3159690>

Qin, Y., Song, D., Chen, H., Cheng, W., Jiang, G., & Cottrell, G. (2017). A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction. Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI), 2627–2633. <https://doi.org/10.24963/ijcai.2017/366>

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. Proceedings of the 3rd International Conference on Learning Representations (ICLR). <https://arxiv.org/abs/1412.6980>

Agarwal, S., & Dhokane, R. M. (2024). LSTM Deep Learning Based Stock Price Prediction with Bollinger Band, RSI, MACD, and OHLC Features. International Journal of Intelligent Systems and Applications in Engineering, 12(3), 1169–1176. <https://ijisae.org/index.php/IJISAE/article/view/5396>

Murphy, J. J. (1999). Technical Analysis of the Financial Markets: A Comprehensive Guide to Trading Methods and Applications. New York Institute of Finance.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems, 30, 5998–6008. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

ภาคผนวก

ภาคผนวก ก. รายละเอียด Features ที่ใช้ในโครงการ

ตารางที่ ก.1 รายละเอียด Features ทั้ง 27 ตัวที่ใช้ในการ Train โมเดล

ลำดับ	Feature	กลุ่ม	คำอธิบาย
1	Return_1d	Price-based	ผลตอบแทนรายวัน (เปลี่ยนแปลง % จากวันก่อน)
2	Return_3d	Price-based	ผลตอบแทนย้อนหลัง 3 วัน
3	Return_5d	Price-based	ผลตอบแทนย้อนหลัง 5 วัน
4	Return_10d	Price-based	ผลตอบแทนย้อนหลัง 10 วัน
5	Volatility_5d	Price-based	ค่าเบี่ยงเบนมาตรฐานของ Return ย้อนหลัง 5 วัน
6	Volatility_20d	Price-based	ค่าเบี่ยงเบนมาตรฐานของ Return ย้อนหลัง 20 วัน
7	MA5	Trend	ค่าเฉลี่ยเคลื่อนที่ 5 วัน
8	MA20	Trend	ค่าเฉลี่ยเคลื่อนที่ 20 วัน
9	MA50	Trend	ค่าเฉลี่ยเคลื่อนที่ 50 วัน
10	EMA12	Trend	Exponential Moving Average 12 วัน
11	EMA26	Trend	Exponential Moving Average 26 วัน
12	Price_MA20_dist	Trend	ระยะห่างของราคาจาก MA20 เป็น %

ลำดับ	Feature	กลุ่ม	คำอธิบาย
13	RSI	Momentum	Relative Strength Index (14 วัน) วัดความแรงของการเปลี่ยนแปลง
14	MACD	Momentum	ผลต่างระหว่าง EMA12 และ EMA26
15	MACD_signal	Momentum	EMA 9 วันของ MACD
16	MACD_diff	Momentum	ผลต่างระหว่าง MACD และ MACD_signal
17	Stoch_k	Momentum	Stochastic Oscillator %K
18	Stoch_d	Momentum	Stochastic Oscillator %D (MA3 ของ %K)
19	Volume_change	Volume	การเปลี่ยนแปลง % ของปริมาณซื้อขาย
20	OBV	Volume	On-Balance Volume สะสมตามทิศทางราคา
21	Volume_MA20	Volume	ค่าเฉลี่ยปริมาณซื้อขาย 20 วัน
22	Volume_MA_ratio	Volume	อัตราส่วนปริมาณซื้อขายวันนี้ต่อ Volume_MA20
23	SP500_return	Market-wide	ผลตอบแทนรายวันของดัชนี S&P 500
24	SP500_MA20	Market-wide	ค่าเฉลี่ยเคลื่อนที่ 20 วันของ S&P 500
25	SP500_vol	Market-wide	ความผันผวนของ S&P 500 ย้อนหลัง 20 วัน

ลำดับ	Feature	กลุ่ม	คำอธิบาย
26	Relative_return	Market-wide	ผลตอบแทนหุ้น ลบด้วย SP500_return
27	Bond_yield	Market-wide	อัตราผลตอบแทนพันธบัตรรัฐบาลสหรัฐอเมริกา 10 ปี (^TNX)

หมายเหตุ: Features ทั้งหมดผ่านการ Normalize ด้วย StandardScaler ก่อน Train และสร้างเป็น Sequence ขนาด 60 วัน (Sliding Window) เพื่อเป็น Input ให้โมเดล LSTM + Attention Mechanism

ภาคผนวก ข. ผลการทดลอง SHAP Feature Importance รายหุ้น

ตารางที่ ข.1 สรุป SHAP Top-5 Feature Importance ของแต่ละหุ้นจากโมเดล LSTM + Attention Mechanism

หุ้น (Sector)	SHAP Top-5 Features (เรียงตามความสำคัญ)	Threshold
NVDA (Technology)	Bond_yield, Volatility_5d, SP500_MA20, OBV, VIX_change	0.30
TSLA (Technology)	Volatility_5d, Bond_yield, RSI, Volume_change, OBV	0.30
JNJ (Healthcare)	OBV, Relative_return, RSI, Return_5d, Volume_MA_ratio	0.30
UNH (Healthcare)	OBV, RSI, Return_3d, Volume_change, MACD_diff	0.30
XOM (Energy)	SP500_MA20, Bond_yield, SP500_return, OBV, Volatility_5d	0.30
CVX (Energy)	SP500_MA20, Bond_yield, SP500_vol, OBV, Return_5d	0.30
JPM (Finance)	Bond_yield, SP500_MA20, Volume_MA_ratio, OBV, Return_3d	0.30
GS (Finance)	Bond_yield, OBV, SP500_return, Volume_change, MACD	0.30
AMZN (Consumer)	Bond_yield, OBV, Volatility_5d, SP500_MA20, Volume_MA_ratio	0.30
COST (Consumer)	OBV, Bond_yield, Volume_MA_ratio, RSI, Return_5d	0.30

ข้อสังเกต: Bond_yield ปรากฏใน Top-5 SHAP ของ 8 จาก 10 หุ้น และ OBV ปรากฏใน Top-5 ของทุกหุ้น แสดงให้เห็นว่าทั้งสอง Feature มีความสำคัญในเชิง Cross-stock Consistency สูงมาก

ภาคผนวก ค. รายละเอียด Hyperparameters และ Environment

ตารางที่ ค.1 Hyperparameters ของโมเดล LSTM + Attention Mechanism

Hyperparameter	ค่าที่ใช้	เหตุผล
Hidden Size	128	สมดุลระหว่าง Model Capacity และ Overfitting
LSTM Layers	3	จับ Pattern ระดับต่างๆ ได้ครอบคลุมขึ้น
Attention Layer	Temporal Attention	จับความสัมพันธ์เชิงเวลาระหว่าง Time Steps ช่วยให้โมเดลเน้นวันที่มีนัยสำคัญต่อการพยากรณ์
Dropout	0.2	ป้องกัน Overfitting
Sequence Length	60 วัน	60 วันทำการ $\approx$ 3 เดือนปฏิทิน ครอบคลุมหนึ่งรอบประกาศผลประกอบการรายไตรมาส (Quarterly Earnings Cycle)
Batch Size	32	มาตรฐานสำหรับ Time-series
Learning Rate	0.001	Adam default ที่เหมาะกับ LSTM
Weight Decay	1e-5	L2 Regularization ป้องกัน Overfitting
Focal Loss Gamma	2.0	แก้ Class Imbalance ได้ดีกว่า gamma=1
Early Stopping Patience	20 epochs	ให้โมเดลเวลาเพียงพอก่อนหยุด
Monitor Metric	F1-Score	เหมาะกับ Imbalanced data มากกว่า Accuracy
Optimal Threshold	0.30	Scan 0.30–0.70 เพื่อ Maximize F1-Score บน Validation Set; ค่า 0.30 เหมาะกับ Focal Loss (gamma=2) ที่ดัน Probability ของ Minority Class ให้ต่ำกว่า 0.5 โดยธรรมชาติ
Train/Test Split	80% / 20%	Time-ordered ไม่สุ่ม ป้องกัน Data Leakage

ตารางที่ ค.2 Software และ Hardware Environment

รายการ	รายละเอียด
Operating System	Windows 11
Python Version	3.10.x (conda environment: stock_project)
PyTorch	2.7.1+cu118
CUDA Version	11.8
GPU	NVIDIA GeForce RTX 3050 Laptop (4GB VRAM)
CPU	Intel Core i7 (12th Gen)
RAM	24 GB
Key Libraries	yfinance, scikit-learn, shap, ta, pandas, numpy, matplotlib, seaborn

